1. Прогнозирование заказов такси

1.1 Цель работы

```
Компания «Чётенькое такси» собрала исторические данные о заказах такси в
аэропортах. Чтобы привлекать больше водителей в период пиковой нагрузки,
нужно спрогнозировать количество заказов такси на следующий час. Необходимо
проанализировать данные, представить их в удобном виде, выявить тренд и
сезонность данных, обучить несколько моделей на разных алгоритмах с
меняющимися гиперпараметрами и выбрать наилучшую модель для
прогнозирования. Количество заказов находится в столбце 'num_orders'
```

2. Работа с данными

2.1. Подготовка

Ввод [1]:

```
import pandas as pd
from statsmodels.tsa.seasonal import seasonal_decompose
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor
from catboost import CatBoostRegressor
```

Ввод [2]:

```
data = pd.read_csv('/datasets/taxi.csv')
```

Ввод [3]:

```
display(data.head())
display(data[data['num_orders'].isna()])
```

	datetime	num_orders
0	2018-03-01 00:00:00	9
1	2018-03-01 00:10:00	14
2	2018-03-01 00:20:00	28
3	2018-03-01 00:30:00	20
4	2018-03-01 00:40:00	32

datetime	num_orders

На первый взгляд данные чистые

Ввод [4]:

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 26496 entries, 0 to 26495
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   datetime    26496 non-null  object
 1   num_orders  26496 non-null  int64
dtypes: int64(1), object(1)
memory usage: 414.1+ KB
```

Превратим datetime в соответствующий тип данных

Ввод [5]:

```
data['datetime'] = pd.to_datetime(data['datetime'])
```

Ввод [6]:

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 26496 entries, 0 to 26495
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   datetime    26496 non-null  datetime64[ns]
 1   num_orders  26496 non-null  int64
dtypes: datetime64[ns](1), int64(1)
memory usage: 414.1 KB
```

Внесем данные времени в индексы

Ввод [7]:

```
data.set_index('datetime', inplace=True)
```

Ввод [8]:

```
data.head()
```

Out[8]:

datetime	num_orders
2018-03-01 00:00:00	9
2018-03-01 00:10:00	14
2018-03-01 00:20:00	28
2018-03-01 00:30:00	20
2018-03-01 00:40:00	32

Шаг в 10 минут. Ресемплирование будем выполнять по часу, с агрегацией среднего

Ввод [9]:

```
data = data.resample('1H').sum()
```

Ввод [10]:

```
data.head()
```

Out[10]:

datetime	num_orders
2018-03-01 00:00:00	124
2018-03-01 01:00:00	85
2018-03-01 02:00:00	71
2018-03-01 03:00:00	66
2018-03-01 04:00:00	43

Для комфортного анализа отсортируем индексы

Ввод [11]:

```
data.sort_index(inplace=True)
```

Ввод [12]:

```
data.index.is_monotonic
```

Out[12]:

```
True
```

Отлично, время находится там, где нужно, шаг в один час, данные отсортированы

Ввод [13]:

```
print(f'min: {data.index.min()}')
print(f'max: {data.index.max()}')
```

```
min: 2018-03-01 00:00:00
max: 2018-08-31 23:00:00
```

Имеем данные за полгода - с начала марта 2018 до конца августа 2018

2.2. Анализ

2.2.1. Технический анализ

Посмотрим данные на графике

Ввод [14]:

```
data.plot(figsize=(12, 9))
```

Out[14]:

```
<AxesSubplot:xlabel='datetime'>
```

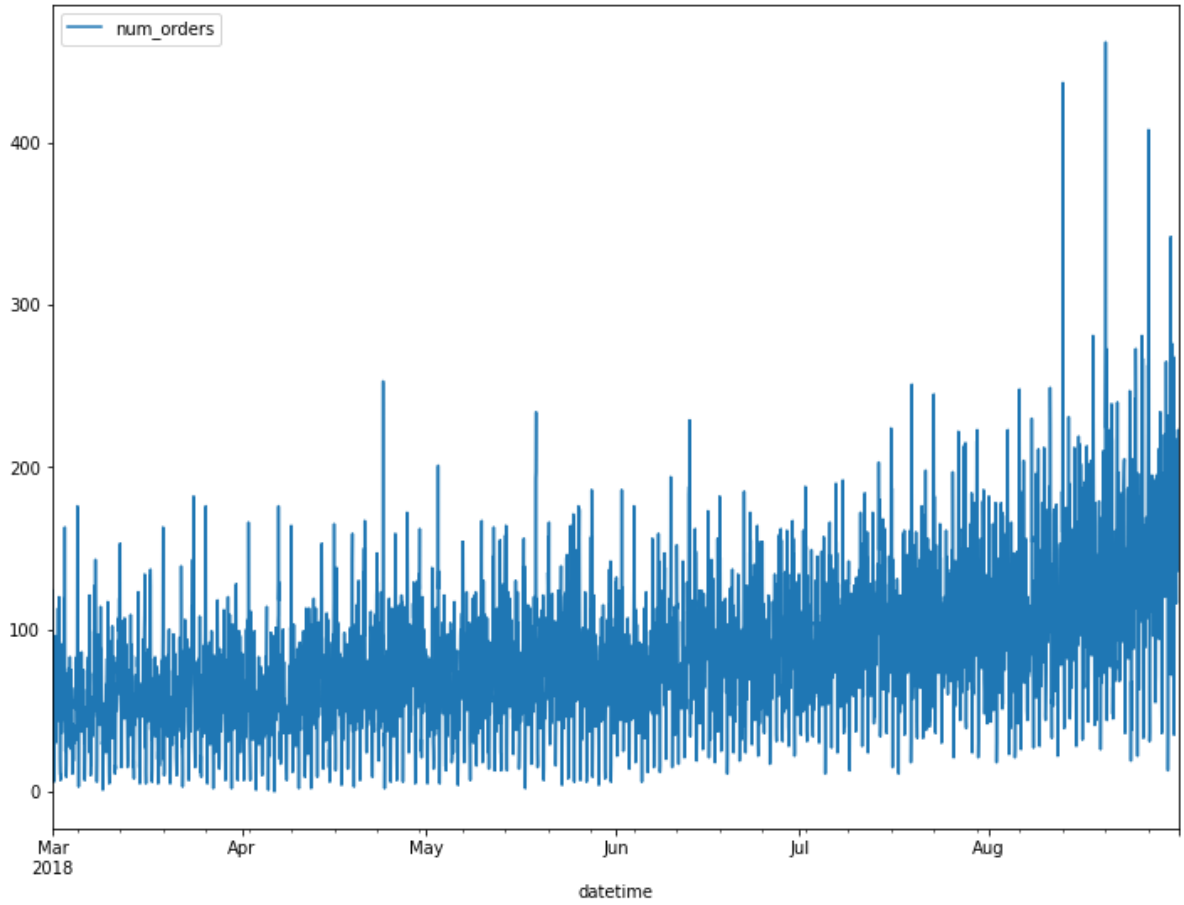

Видно, что тренд (довольно слабый) присутствует, обеспечивая стационарность. На первый взгляд сезонность имеется, однако, стоит провести чуть более глубокий анализ

Посмотрим на скользящее среднее с окном в 1 и 5 дней

Ввод [15]:

```
data['1_roll'] = data['num_orders'].rolling(24).mean()
data['5_roll'] = data['num_orders'].rolling(24*5).mean()
```

Ввод [16]:

```
data.plot(figsize=(12, 9))
```

Out[16]:

```
<AxesSubplot:xlabel='datetime'>
```

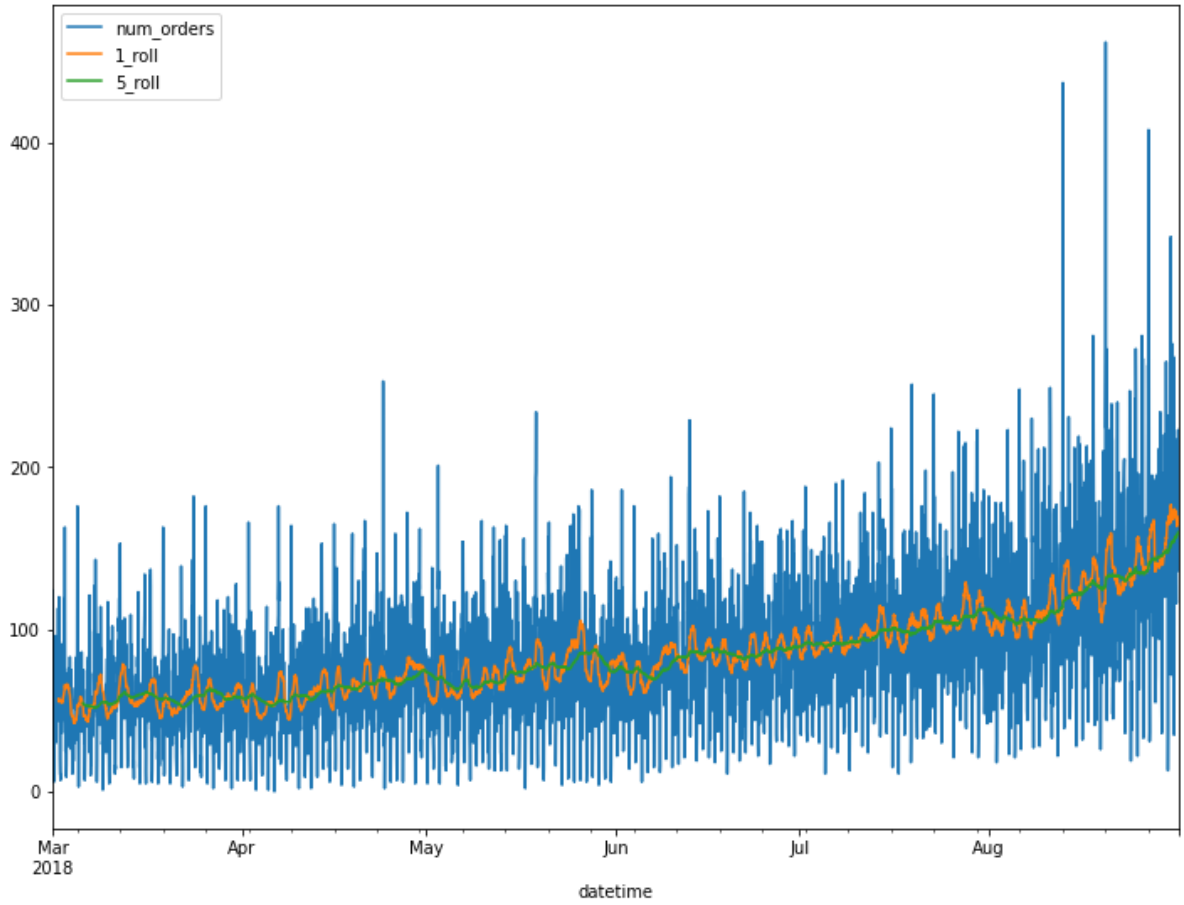

Определенно, тренд заметен. Попробуем узнать сезонность с помощью seasonal_decompose

Ввод [17]:

```
seasonal_decompose(data['num_orders']).trend.plot(figsize=(12, 9))
```

Out[17]:

```
<AxesSubplot:xlabel='datetime'>
```

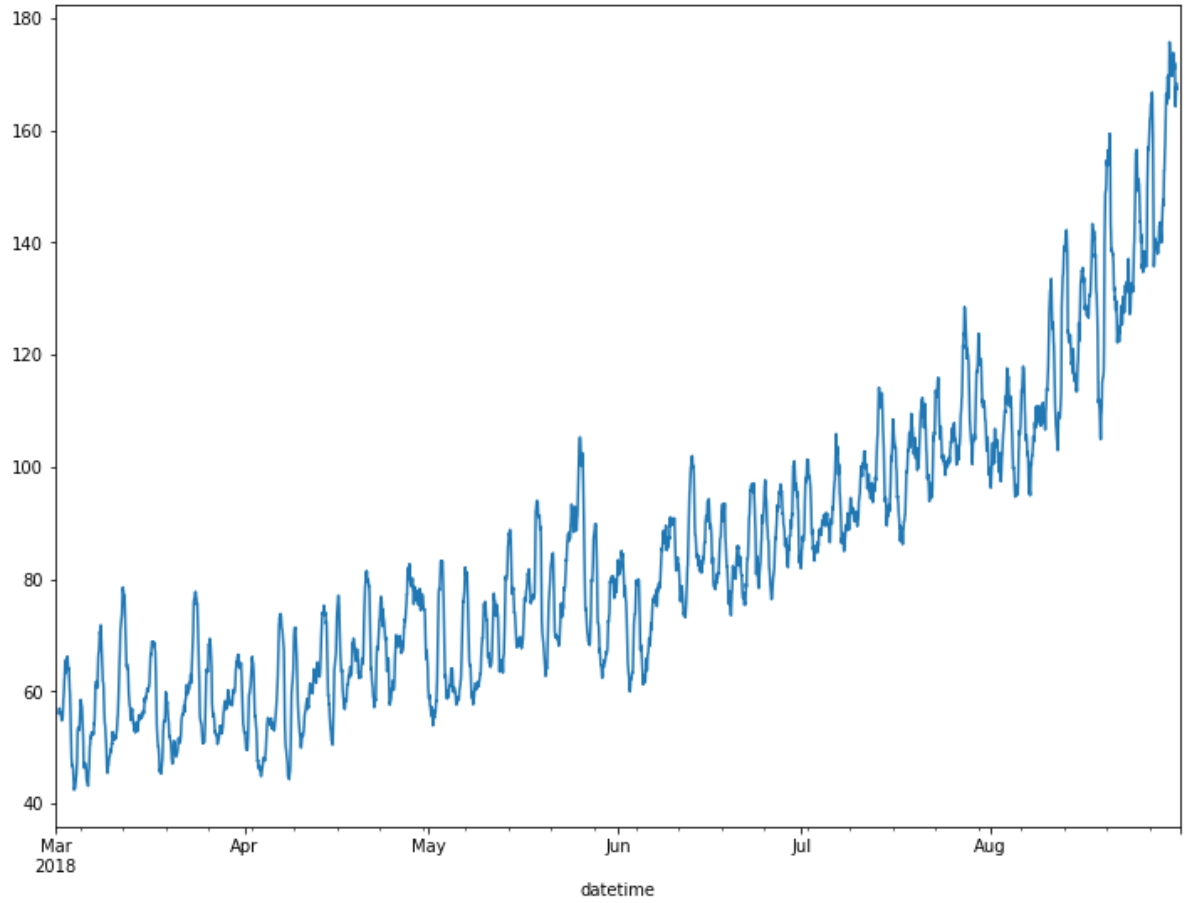

Ввод [18]:

```
seasonal_decompose(data['num_orders']).seasonal.plot(figsize=(12, 9))
```

Out[18]:

```
<AxesSubplot:xlabel='datetime'>
```

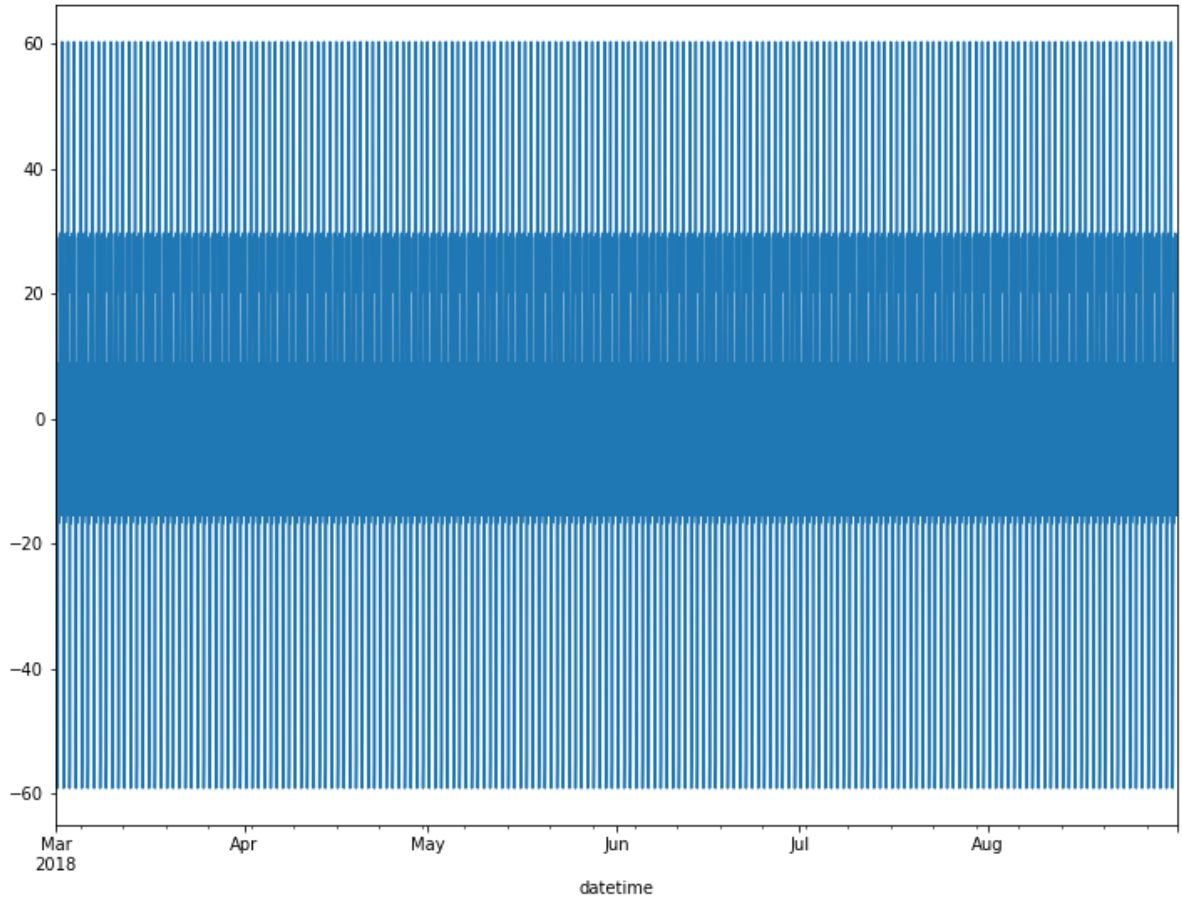

Сезонность стабильна, но посмотрим на нее чуть внимательнее

Ввод [19]:

```
seasonal_decompose(data['num_orders'].iloc[:48]).seasonal.plot(figsize=(12, 9))
```

Out[19]:

```
<AxesSubplot:xlabel='datetime'>
```

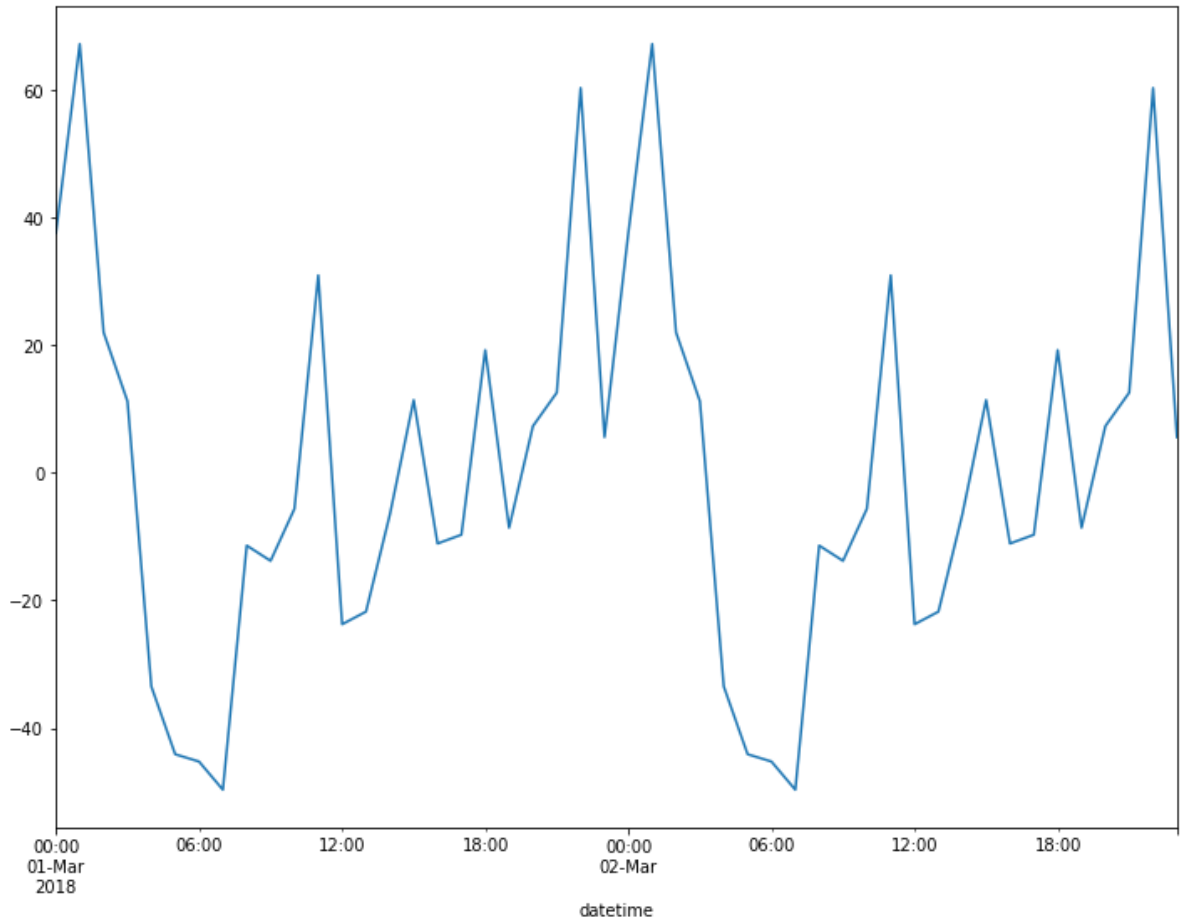

Спад в 6 утра и пик в полночь, похоже на аэропорт

Посмотрим на разности

Ввод [20]:

```
data['time_shift'] = data['num_orders'] - data['num_orders'].shift(24)
```

Ввод [21]:

```
data['time_shift'].plot(figsize=(12, 9))
```

Out[21]:

```
<AxesSubplot:xlabel='datetime'>
```

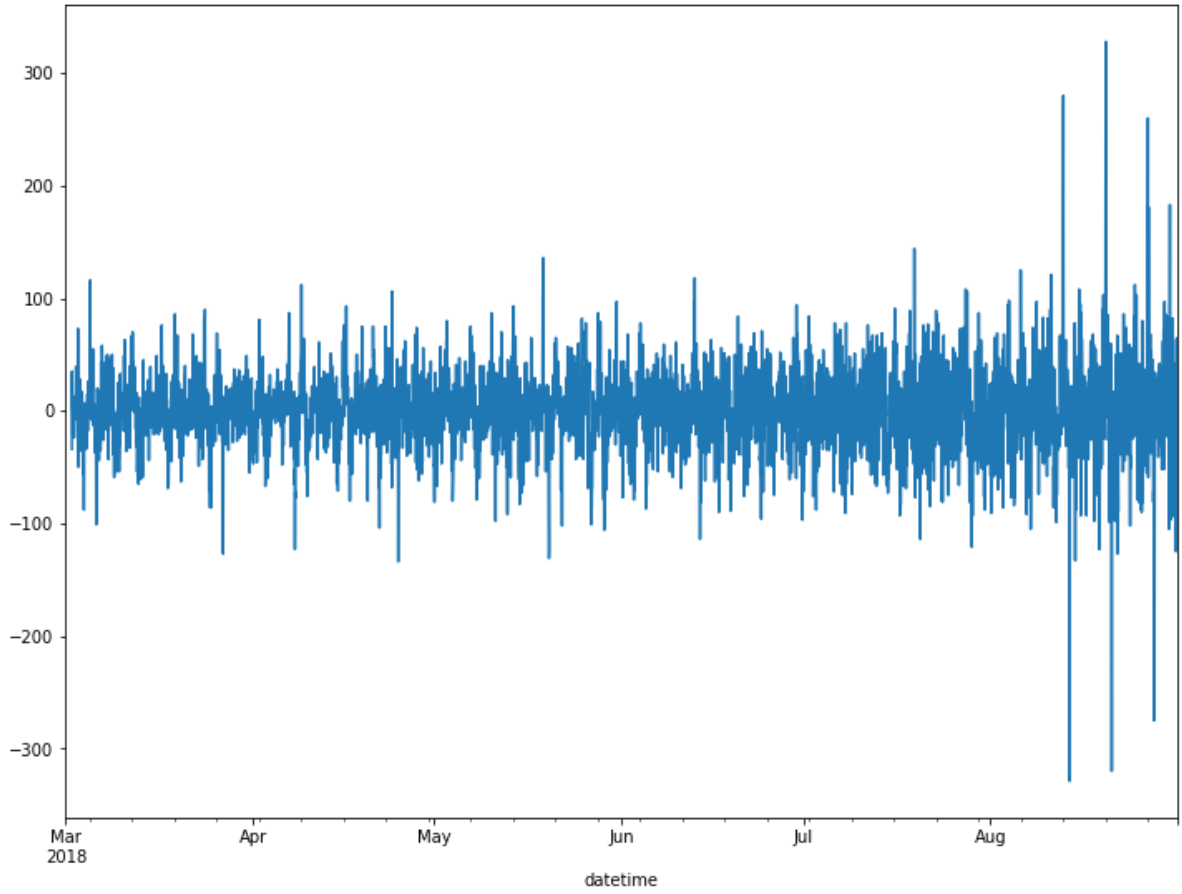

Уверенная стационарность, за исключением стандартного отклонения - под конец оно выше, да и в процессе, бывает, встречается

2.2.2. Выделение признаков

Очистим данные, полученные при анализе

Ввод [22]:

```
data = data[['num_orders']]
```

Создадим функцию, выделяющую основные признаки

Ввод [23]:

```
def create_features(data, lags=3, roll=3):
    data.loc[:, 'day'] = data.index.day
    data.loc[:, 'dayofweek'] = data.index.dayofweek
    data.loc[:, 'hour'] = data.index.hour

    for lag in range(1, lags+1):
        data[f'lag_{lag}'] = data['num_orders'].shift(lag)

    data[f'rolling_{roll}'] = data['num_orders'].shift().rolling(roll).mean()

    return data
```

Отлично, теперь можно переходить к обучению

2.3. Обучение

2.3.1. Универсальная функция

При разделении train : valid : test будем использовать соотношение 75 : 15 : 10

Ввод [24]:

```
def make_split(data, lag, roll):
    # разделяю данные на выборки
    new_data = create_features(data, lag, roll)
    train, valitest = train_test_split(new_data, shuffle=False, train_size=0.75)
    train = train.dropna()
    valid, test = train_test_split(valitest, shuffle=False, test_size=0.4)

    # делю выборки на features и target
    features_train = train.drop('num_orders', axis=1)
    target_train = train['num_orders']
    features_valid = valid.drop('num_orders', axis=1)
    target_valid = valid['num_orders']
    return features_train, target_train, features_valid, target_valid
```

Функция, в которой обучаем модель, предсказываем и отдаем RMSE

Ввод [25]:

```
def make_pred(Algo, features_train, target_train, features_valid, target_valid):
    model = Algo
    model.fit(features_train, target_train)

    # предсказываю и считаю RMSE
    predicted = model.predict(features_valid)
    model_rmse = mean_squared_error(predicted, target_valid)**0.5
    return model_rmse
```

2.3.2. LinearRegression

Начнем с классики - линейная регрессия. Будем перебирать значения лагов и роллинга от 1 до 10, выберем то что даст лучший результат по RMSE

Ввод [26]:

```
%%time

best_rmse = None
best_lag = None
best_roll = None

for lag in range(1, 11):
    for roll in [3, 6, 12, 24, 48]:

        features_train, target_train, features_valid, target_valid = make_split(data
                                                                                lag,
                                                                                roll
        model = LinearRegression()
        model_rmse = make_pred(model, features_train, target_train,
                               features_valid, target_valid)

        if not best_rmse:
            best_rmse = model_rmse
        if model_rmse < best_rmse:
            best_rmse = model_rmse
            best_lag = lag
            best_roll = roll

print((best_rmse, best_lag, best_roll), end='\n\n')
```

```
(39.18269053575869, 9, 48)

CPU times: user 2.18 s, sys: 1.31 s, total: 3.49 s
Wall time: 3.5 s
```

3 секунды, RMSE на уровне 39, лучший лаг 9, лучший ролл 48

2.3.3. DecisionTreeRegressor

Здесь будем перебирать еще так же max_depth

Ввод [27]:

```
%%time

best_rmse = None
best_lag = None
best_roll = None
best_depth = None

for lag in range(1, 11):
    for roll in [3, 6, 12, 24, 48]:
        for max_depth in range(4, 17, 2):

            features_train, target_train, features_valid, target_valid = make_split(


            model = DecisionTreeRegressor(random_state=12345, max_depth=max_depth)
            model_rmse = make_pred(model, features_train, target_train,
                                   features_valid, target_valid)

            if not best_rmse:
                best_rmse = model_rmse
            if model_rmse < best_rmse:
                best_rmse = model_rmse
                best_lag = lag
                best_roll = roll
                best_depth = max_depth

print((best_rmse, best_lag, best_roll, best_depth), end='\n\n')
```

```
(34.1007839781787, 3, 48, 10)

CPU times: user 12.1 s, sys: 54.5 ms, total: 12.1 s
Wall time: 12.2 s
```

Довольно точный - показатель RMSE 34

2.3.4. RandomForestRegressor

Данный показатель ограничим в глубине обучения, так как при высоких настройках это будет супердолго. Однако, добавляются еще n_estimators

Ввод [28]:

```
%%time

best_rmse = None
best_lag = None
best_roll = None
best_depth = None
best_n_estimators = None

for lag in range(4, 7):
    for roll in [24, 36, 48, 60]:
        for max_depth in range(20, 25, 2):
            for n_estimators in range(95, 106, 5):

                features_train, target_train, features_valid, target_valid = make_sp


                model = RandomForestRegressor(random_state=12345,
                                              max_depth=max_depth,
                                              n_estimators=n_estimators)
                model_rmse = make_pred(model, features_train, target_train,
                                              features_valid, target_valid)

                if not best_rmse:
                    best_rmse = model_rmse
                if model_rmse < best_rmse:
                    best_rmse = model_rmse
                    best_lag = lag
                    best_roll = roll
                    best_depth = max_depth
                    best_n_estimators = n_estimators

print((best_rmse, best_lag, best_roll, best_depth, best_n_estimators), end='\n\n')
```

```
(29.85219692218834, 5, 60, 24, 105)

CPU times: user 3min 1s, sys: 580 ms, total: 3min 1s
Wall time: 3min 3s
```

Еще точнее, долгий, но RMSE 30

2.3.5. CatBoostRegressor

Этот алгоритм мы так же ограничим, чтобы не тратить так много времени

Ввод [29]:

```
%%time

best_rmse = None
best_lag = None
best_roll = None
best_n_estimators = None

for lag in range(1, 5):
    for roll in [3, 6, 12, 24, 48]:
        for n_estimators in range(115, 126, 5):

            features_train, target_train, features_valid, target_valid = make_split(


            model = CatBoostRegressor(random_state=12345,
                                      n_estimators=n_estimators,
                                      verbose=0)
            model_rmse = make_pred(model, features_train, target_train,
                                           features_valid, target_valid)

            if not best_rmse:
                best_rmse = model_rmse
            if model_rmse < best_rmse:
                best_rmse = model_rmse
                best_lag = lag
                best_roll = roll
                best_n_estimators = n_estimators

print((best_rmse, best_lag, best_roll, best_n_estimators), end='\n\n')
```

```
(31.17168166258607, 2, 24, 120)

CPU times: user 13.8 s, sys: 1 s, total: 14.8 s
Wall time: 1min 19s
```

Чуть меньшая точность, но более быстрое время работы

2.3.6. Вывод

Берем CatBoostRegressor (ограничения по времени не было, но чуть более низкая точность не перекрывает скорости) с настройками лаги = 2, роллинг = 24, n_estimators = 120

2.4. Тестирование

Ввод [30]:

```
new_data = create_features(data.copy(), 5, 60)
train, test = train_test_split(new_data, shuffle=False, train_size=0.9)
train = train.dropna()

# делю выборки на features и target
features_train = train.drop('num_orders', axis=1)
target_train = train['num_orders']
features_test = test.drop('num_orders', axis=1)
target_test = test['num_orders']
```

Ввод [31]:

```
test_model = RandomForestRegressor(random_state=12345, max_depth=24, n_estimators=10

test_model.fit(features_train, target_train)

predicted = test_model.predict(features_test)
```

Ввод [34]:

```
test_rmse = mean_squared_error(predicted, target_test)**0.5

print(test_rmse)
```

2.5. Вывод

Были проверены 4 модели машинного обучения:

- Линейная регрессия

- Дерево решений

- Рандомный лес деревьев

- Регрессор CatBoost

Лучше всех себя показал CatBoostRegressor с доп. настройками. На тестовых данных значение RMSE составило 9.5