3. Отток клиентов

Из «Бета-Банка» стали уходить клиенты. Каждый месяц. Немного, но заметно. Банковские маркетологи посчитали: сохранять текущих клиентов дешевле, чем привлекать новых.

Нужно спрогнозировать, уйдёт клиент из банка в ближайшее время или нет. Вам предоставлены исторические данные о поведении клиентов и расторжении договоров с банком.

3.1. Подготовка данных

3.1.1. Импорты

Импортируем все необходимые модули

Ввод [67]:

```
import pandas as pd
from sklearn.preprocessing import OneHotEncoder
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score
from sklearn.metrics import roc_auc_score
from sklearn.utils import shuffle
from sklearn.metrics import roc_curve
import matplotlib.pyplot as plt
```

Ввод [68]:

```
data = pd.read_csv('/datasets/Churn.csv')
```

3.1.2. Знакомство с данными

Краткий взгляд на данные

Ввод [69]:

```
display(data.head())
print('\n\n')
print(data.info())
print('\n\n')
print(data.describe())
```

	RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance
0	1	15634602	Hargrave	619	France	Female	42	2.0	0.0
1	2	15647311	Hill	608	Spain	Female	41	1.0	83807.8
2	3	15619304	Onio	502	France	Female	42	8.0	159660.8
3	4	15701354	Boni	699	France	Female	39	1.0	0.0
4	5	15737888	Mitchell	850	Spain	Female	43	2.0	125510.8

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 14 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   RowNumber        10000 non-null  int64
 1   CustomerId       10000 non-null  int64
 2   Surname          10000 non-null  object
 3   CreditScore      10000 non-null  int64
 4   Geography        10000 non-null  object
 5   Gender           10000 non-null  object
 6   Age              10000 non-null  int64
 7   Tenure           9091 non-null   float64
 8   Balance          10000 non-null  float64
 9   NumOfProducts    10000 non-null  int64
 10  HasCrCard        10000 non-null  int64
 11  IsActiveMember   10000 non-null  int64
 12  EstimatedSalary  10000 non-null  float64
 13  Exited           10000 non-null  int64
dtypes: float64(3), int64(8), object(3)
memory usage: 1.1+ MB
None


         RowNumber    CustomerId   CreditScore           Age       Ten
ure  \
count  10000.00000  1.000000e+04  10000.000000  10000.000000  9091.000
000
mean    5000.50000  1.569094e+07    650.528800     38.921800     4.997
690
std     2886.89568  7.193619e+04     96.653299     10.487806     2.894
723
min        1.00000  1.556570e+07    350.000000     18.000000     0.000
000
25%     2500.75000  1.562853e+07    584.000000     32.000000     2.000
000
50%     5000.50000  1.569074e+07    652.000000     37.000000     5.000
000
75%     7500.25000  1.575323e+07    718.000000     44.000000     7.000
```

```
000
max    10000.00000  1.581569e+07    850.000000     92.000000    10.000
000

             Balance  NumOfProducts    HasCrCard  IsActiveMember  \
count   10000.000000   10000.000000  10000.00000    10000.000000
mean    76485.889288       1.530200      0.70550        0.515100
std     62397.405202       0.581654      0.45584        0.499797
min         0.000000       1.000000      0.00000        0.000000
25%         0.000000       1.000000      0.00000        0.000000
50%     97198.540000       1.000000      1.00000        1.000000
75%    127644.240000       2.000000      1.00000        1.000000
max    250898.090000       4.000000      1.00000        1.000000

       EstimatedSalary        Exited
count     10000.000000  10000.000000
mean     100090.239881      0.203700
std       57510.492818      0.402769
min          11.580000      0.000000
25%       51002.110000      0.000000
50%      100193.915000      0.000000
75%      149388.247500      0.000000
max      199992.480000      1.000000
```

Допустим, зарплата в 11 чего-бы-то-ни-было нас не смутит (хотя, вопрос остается)

Имеем следующую картину:

- один бесполезный столбец "RowNumber"

- 9 числовых признаков

- 3 категориальных признака

- в одном столбце имеется 989 ошибочных данных

Избавимся от RowNumber

Ввод [70]:

```
data = data.drop('RowNumber', axis=1)
```

Фамилия и id человека, скорее всего, не несут никакой информации, поэтому их стоит исключить из датасета

Ввод [71]:

```
data = data.drop(['Surname', 'CustomerId'], axis=1)
```

3.1.3. Заполнение пропусков

Tenure – показатель, сколько лет человек является клиентом банка. Если стоит пропуск, то, скорее всего, человек только что пришел в банк.

Ввод [72]:

```
print('Количество нулевых объектов:', data[data.Tenure == 0].Tenure.count())
print('Минимальное значение', data.Tenure.min())
print('Максимальное значение', data.Tenure.max())
```

```
Количество нулевых объектов: 382
Минимальное значение 0.0
Максимальное значение 10.0
```

Людей с нулевым количеством лет имеется в количестве 382 человека. Либо это пропуски совсем новых людей, либо надо уточнить – теория о том, что это люди с 10+ лет клиентства, но цифра не влезла не сработает – число 10 есть в таблице

За неимением альтернатив, за правду берем теорию, что это новые люди

Ввод [73]:

```
data.Tenure = data.Tenure.fillna(0)
print(data[data.Tenure.isna()].Tenure.count())
```

```
0
```

Ошибок в датасете больше нет

3.1.4. Приведение к нижнему регистру

Приведем названия столбцов к нижнему регистру и разделим нижним подчеркиванием

Ввод [74]:

```
# переименуем колонки, которые надо разделить
data = data.rename(columns={'CustomerId': 'customer_id',
                            'CreditScore': 'credit_score',
                            'NumOfProducts': 'num_of_products',
                            'HasCrCard': 'has_cr_card',
                            'IsActiveMember': 'is_active_member',
                            'EstimatedSalary': 'estimated_salary'})

# приведем все к нижнему регистру
data.columns = data.columns.str.lower()

# посмотрим на результат
data.head()
```

Out[74]:

	credit_score	geography	gender	age	tenure	balance	num_of_products	has_cr_card	is_a
0	619	France	Female	42	2.0	0.00	1	1	
1	608	Spain	Female	41	1.0	83807.86	1	0	
2	502	France	Female	42	8.0	159660.80	3	1	
3	699	France	Female	39	1.0	0.00	2	0	
4	850	Spain	Female	43	2.0	125510.82	1	1	

3.1.5. Замена категориальных признаков

Осталось две колонки с категориальными признаками. Проверим их на адекватность

Ввод [75]:

```
print(f'geography unique: {data.geography.unique()}')
print(f'gender unique: {data.gender.unique()}')
```

```
geography unique: ['France' 'Spain' 'Germany']
gender unique: ['Female' 'Male']
```

Выглядит культурно, стоит заменить их числами при помощи OneHot-технологий

Ввод [76]:

```
data_ordinal = (pd
                # соединяем исходную таблицу с преобразованной
                .concat([pd.get_dummies(data[['geography', 'gender']], drop_first=Tr
                # убираем старые столбцы
                .drop(['geography', 'gender'], axis=1))
```

Ввод [77]:

```
data_ordinal.head()
```

Out[77]:

	geography_Germany	geography_Spain	gender_Male	credit_score	age	tenure	balance	nu
0	0	0	0	619	42	2.0	0.00	
1	0	1	0	608	41	1.0	83807.86	
2	0	0	0	502	42	8.0	159660.80	
3	0	0	0	699	39	1.0	0.00	
4	0	1	0	850	43	2.0	125510.82	

3.1.6. Вывод

Краткий вывод: данные чистые, ошибочных значений 10% и только в одной строке. Бесполезных столбцов 3, были убраны. Категориальные признаки переведены в числовые, однако, остается вопрос о поведении модели при обнаружении другой страны

3.2. Исследование задачи

3.2.1. Исследование дисбаланса

Проверим балансировку целевого признака: exited

Ввод [78]:

```
data_ordinal.exited.hist(bins=2)
```

Out[78]:

```
<AxesSubplot:>
```

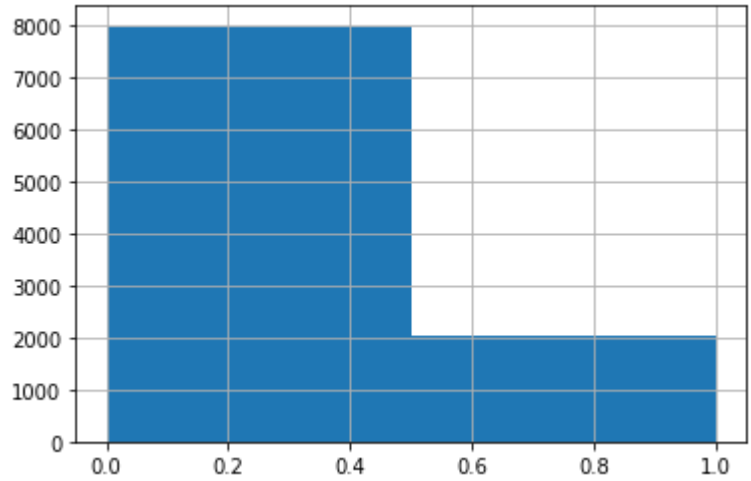

В 4 раза больше преобладают нули, це явный дисбаланс. По сценарию мы наивно его игнорируем, но в голове держим

3.2.2. Разделение данных

Выделим признаки для обучения и целевой признак

Ввод [79]:

```
features = data_ordinal.drop('exited', axis=1)
target = data_ordinal.exited
```

Разделим наши данные на тренировочную, валидационную и тестовую выборки в соотношении 3:1:1

Ввод [80]:

```
Features_, features_test, Target_, target_test = train_test_split(features,
                                                                  target,
                                                                  test_size=0.2,
                                                                  random_state=123
```

Ввод [81]:

```
features_train, features_valid, target_train, target_valid = train_test_split(Featur
                                                                              Target
                                                                              test_s
                                                                              random
```

Ввод [82]:

```
scalable_columns = ['credit_score', 'age', 'tenure', 'balance', 'estimated_salary']
scaler = StandardScaler()
scaler.fit(features_train[scalable_columns])
features_train[scalable_columns] = scaler.transform(features_train[scalable_columns]
features_valid[scalable_columns] = scaler.transform(features_valid[scalable_columns]
features_test[scalable_columns] = scaler.transform(features_test[scalable_columns])
```

```
/tmp/ipykernel_25/2504254674.py:4: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  features_train[scalable_columns] = scaler.transform(features_train[s
calable_columns])
/opt/conda/lib/python3.9/site-packages/pandas/core/indexing.py:1738: S
ettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  self._setitem_single_column(loc, value[:, i].tolist(), pi)
/tmp/ipykernel_25/2504254674.py:5: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  features_valid[scalable_columns] = scaler.transform(features_valid[s
calable_columns])
/opt/conda/lib/python3.9/site-packages/pandas/core/indexing.py:1738: S
ettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  self._setitem_single_column(loc, value[:, i].tolist(), pi)
/tmp/ipykernel_25/2504254674.py:6: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  features_test[scalable_columns] = scaler.transform(features_test[sca
lable_columns])
/opt/conda/lib/python3.9/site-packages/pandas/core/indexing.py:1738: S
ettingWithCopyWarning:
```

```
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas
-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
 (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.htm
l#returning-a-view-versus-a-copy)
  self._setitem_single_column(loc, value[:, i].tolist(), pi)
```

3.2.3. Подбор модели DecisionTreeClassifier

```
Переберем вариации настроек модели DecisionTreeClassifier и выберем лучшую
```

Ввод [83]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    model = DecisionTreeClassifier(max_depth=depth, random_state=12345)
    model.fit(features_train, target_train)
    predicted_valid = model.predict(features_valid)
    f1_predicted = f1_score(target_valid, predicted_valid)
    roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_val
    print(f'max_depth: {depth}, f1: {f1_predicted}, roc auc: {roc_auc_predicted}')
    if f1_predicted > f1_best:
        f1_best = f1_predicted
        best_model = model
        roc_auc_best = roc_auc_predicted
        best_depth = depth
```

```
max_depth: 1, f1: 0.0, roc auc: 0.6878236397271184
max_depth: 2, f1: 0.50853889943074, roc auc: 0.7455832321859787
max_depth: 3, f1: 0.3921568627450979, roc auc: 0.7986544221114478
max_depth: 4, f1: 0.43645083932853723, roc auc: 0.812114017878272
max_depth: 5, f1: 0.5642994241842609, roc auc: 0.8301831339649001
max_depth: 6, f1: 0.5176991150442477, roc auc: 0.8148227313093684
max_depth: 7, f1: 0.54989816700611, roc auc: 0.8115580255018563
max_depth: 8, f1: 0.5411764705882353, roc auc: 0.7893145135639239
max_depth: 9, f1: 0.5306930693069308, roc auc: 0.7599716024031085
max_depth: 10, f1: 0.5305343511450381, roc auc: 0.7456862879811497
max_depth: 11, f1: 0.5263157894736842, roc auc: 0.7269339501413519
max_depth: 12, f1: 0.5152057245080501, roc auc: 0.7065250858162146
max_depth: 13, f1: 0.4863883847549909, roc auc: 0.689809690298251
max_depth: 14, f1: 0.4788732394366197, roc auc: 0.6921748844121112
max_depth: 15, f1: 0.4797297297297297, roc auc: 0.7016356608675517
max_depth: 16, f1: 0.47804878048780486, roc auc: 0.6976622874315188
max_depth: 17, f1: 0.46496815286624205, roc auc: 0.6833706115407222
max_depth: 18, f1: 0.4763458401305057, roc auc: 0.6809252629195071
max_depth: 19, f1: 0.49044585987261147, roc auc: 0.6863846754760287
max_depth: 20, f1: 0.46474358974358976, roc auc: 0.6716553305291979
max_depth: 21, f1: 0.45569620253164556, roc auc: 0.66509156698245
max_depth: 22, f1: 0.4651898734177215, roc auc: 0.6714199561822026
max_depth: 23, f1: 0.48673946957878317, roc auc: 0.6868897761017428
max_depth: 24, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 25, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 26, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 27, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 28, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 29, f1: 0.4746835443037975, roc auc: 0.6785193554050857
max_depth: 30, f1: 0.4746835443037975, roc auc: 0.6785193554050857
```

Узнаем лучший результат по f1, roc_auc и лучшую глубину

Ввод [84]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
```

```
f1_best: 0.5642994241842609
roc_auc_best: 0.8301831339649001
best_depth: 5
```

Не самые плохие показатели, но далеко от идеала

3.2.4. Подбор модели RandomForestClassifier

Переберем вариации настроек модели RandomForestClassifier и выберем лучшую

Ввод [85]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    for estimators in range(5, 101, 5):
        model = RandomForestClassifier(n_estimators=estimators,
                                       max_depth=depth,
                                       random_state=12345)
        model.fit(features_train, target_train)
        predicted_valid = model.predict(features_valid)
        f1_predicted = f1_score(target_valid, predicted_valid)
        roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features
        if f1_predicted > f1_best:
            f1_best = f1_predicted
            best_model = model
            roc_auc_best = roc_auc_predicted
            best_depth = depth
            best_estimators = estimators
```

Лучшие f1, roc_auc, глубина и количество деревьев

Ввод [86]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
print(f'best_estimators: {best_estimators}')
```

```
f1_best: 0.5996055226824458
roc_auc_best: 0.853999200999514
best_depth: 21
best_estimators: 65
```

Примерно те же масштабы трагедии

3.2.5. Подбор модели LogisticRegression

Ввод [87]:

```
model = LogisticRegression()
model.fit(features_train, target_train)
predicted_valid = model.predict(features_valid)
f1_predicted = f1_score(target_valid, predicted_valid)
roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_valid)[
```

Ввод [88]:

```
f1_predicted
```

Out[88]:

```
0.3073286052009456
```

Ввод [89]:

```
roc_auc_predicted
```

Out[89]:

```
0.7638342862813652
```

Показатели все еще далеко не на уровне

3.2.6. Вывод

Краткий вывод: модели показывают результат, но заметно, что есть сильный дисбаланс - из за большого количества единиц предсказания скорее случайные, нежели осмысленные

3.3. Борьба с дисбалансом

3.3.1. Увеличение выборки

Попробуем сначала увеличить количество целевых признаков с единичкой для уравниваня размеров классов

Ввод [90]:

```
print(f'data_ordinal_ones: {data_ordinal.loc[data_ordinal.exited == 1, "exited"].cou
print(f'data_ordinal_zeros: {data_ordinal.loc[data_ordinal.exited == 0, "exited"].cc
```

```
data_ordinal_ones: 2037
data_ordinal_zeros: 7963
```

Значит, увеличиваем единички в 4 раза

Ввод [91]:

```
def upsampled(features, target, repeat):
    features_zeros_class = features[target == 0]
    features_ones_class = features[target == 1]
    target_zeros_class = target[target == 0]
    target_ones_class = target[target == 1]
    features_upsampled = pd.concat([features_zeros_class] + [features_ones_class] *
    target_upsampled = pd.concat([target_zeros_class] + [target_ones_class] * repeat
    features_upsampled, target_upsampled = shuffle(features_upsampled, target_upsamp
    return features_upsampled, target_upsampled

features_upsampled_train, target_upsampled_train = upsampled(features_train, target_
```

3.3.1.1. Подбор модели DecisionTreeClassifier

Переберем вариации настроек модели DecisionTreeClassifier после балансировки и выберем лучшую

Ввод [92]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    model = DecisionTreeClassifier(max_depth=depth, random_state=12345)
    model.fit(features_upsampled_train, target_upsampled_train)
    predicted_valid = model.predict(features_valid)
    f1_predicted = f1_score(target_valid, predicted_valid)
    roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_val
    if f1_predicted > f1_best:
        f1_best = f1_predicted
        best_model = model
        roc_auc_best = roc_auc_predicted
        best_depth = depth
```

Узнаем лучший результат по f1, roc_auc и лучшую глубину

Ввод [93]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
```

```
f1_best: 0.5588972431077694
roc_auc_best: 0.8224997519027153
best_depth: 6
```

Результат не лучше, показатели уменьшились

3.3.1.2. Подбор модели RandomForestClassifier

Исследуем модель RandomForestClassifier

Ввод [94]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    for estimators in range(5, 101, 5):
        model = RandomForestClassifier(n_estimators=estimators,
                                       max_depth=depth,
                                       random_state=12345)
        model.fit(features_upsampled_train, target_upsampled_train)
        predicted_valid = model.predict(features_valid)
        f1_predicted = f1_score(target_valid, predicted_valid)
        roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features
        if f1_predicted > f1_best:
            f1_best = f1_predicted
            best_model = model
            roc_auc_best = roc_auc_predicted
            best_depth = depth
            best_estimators = estimators
```

Результаты:

Ввод [95]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
print(f'best_estimators: {best_estimators}')
```

```
f1_best: 0.6282722513089005
roc_auc_best: 0.8491441279825747
best_depth: 17
best_estimators: 60
```

Здесь показатели чуть лучше

3.3.1.3. Подбор модели LogisticRegression

Ввод [96]:

```
model = LogisticRegression()
model.fit(features_upsampled_train, target_upsampled_train)
predicted_valid = model.predict(features_valid)
f1_predicted = f1_score(target_valid, predicted_valid)
roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_valid)[
```

Ввод [97]:

```
f1_predicted
```

Out[97]:

```
0.4629213483146067
```

Ввод [98]:

```
roc_auc_predicted
```

Out[98]:

```
0.7671880526526051
```

Показатели сильно хуже, данные не линейные, запихнуть в логистическую регрессию сложновато

3.3.2. Уменьшение выборки

Теперь попробуем обратный путь - уменьшим количество нулей в 4 раза и посмотрим на результат

Ввод [100]:

```
def downsample(features, target, fraction):
    features_zeros = features[target == 0]
    features_ones = features[target == 1]
    target_zeros = target[target == 0]
    target_ones = target[target == 1]
    features_downsampled = pd.concat([features_zeros.sample(frac=fraction,
                                                            random_state=12345)] + [
    target_downsampled = pd.concat([target_zeros.sample(frac=fraction,
                                                        random_state=12345)] + [targ
    features_downsampled, target_downsampled = shuffle(features_downsampled,
                                                       target_downsampled,
                                                       random_state=12345)
    return features_downsampled, target_downsampled

features_downsampled_train, target_downsampled_train = downsample(features_train, ta
```

3.3.2.1. Подбор модели DecisionTreeClassifier

Переберем вариации настроек модели DecisionTreeClassifier после новой балансировки и выберем лучшую

Ввод [101]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    model = DecisionTreeClassifier(max_depth=depth, random_state=12345)
    model.fit(features_downsampled_train, target_downsampled_train)
    predicted_valid = model.predict(features_valid)
    f1_predicted = f1_score(target_valid, predicted_valid)
    roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_val
    if f1_predicted > f1_best:
        f1_best = f1_predicted
        best_model = model
        roc_auc_best = roc_auc_predicted
        best_depth = depth
```

Ввод [102]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
```

```
f1_best: 0.5468354430379746
roc_auc_best: 0.8103022715532926
best_depth: 7
```

Здесь даже меньше. По границе не проходим, уменьшение явно не пошло на пользу

3.3.2.2. Подбор модели RandomForestClassifier

Исследуем модель RandomForestClassifier

Ввод [103]:

```
f1_best = 0
roc_auc_best = 0
best_depth = 0
best_model = None

for depth in range(1, 31):
    for estimators in range(5, 101, 5):
        model = RandomForestClassifier(n_estimators=estimators,
                                       max_depth=depth,
                                       random_state=12345)
        model.fit(features_downsampled_train, target_downsampled_train)
        predicted_valid = model.predict(features_valid)
        f1_predicted = f1_score(target_valid, predicted_valid)
        roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features
        if f1_predicted > f1_best:
            f1_best = f1_predicted
            best_model = model
            roc_auc_best = roc_auc_predicted
            best_depth = depth
            best_estimators = estimators
```

Результаты:

Ввод [104]:

```
print(f'f1_best: {f1_best}')
print(f'roc_auc_best: {roc_auc_best}')
print(f'best_depth: {best_depth}')
print(f'best_estimators: {best_estimators}')
```

```
f1_best: 0.5764854614412137
roc_auc_best: 0.8536785829700934
best_depth: 10
best_estimators: 75
```

Чуть лучше, но не тот результат, что был при увеличении выборки

3.3.2.3. Подбор модели LogisticRegression

Ввод [105]:

```
model = LogisticRegression()
model.fit(features_downsampled_train, target_downsampled_train)
predicted_valid = model.predict(features_valid)
f1_predicted = f1_score(target_valid, predicted_valid)
roc_auc_predicted = roc_auc_score(target_valid, model.predict_proba(features_valid)[
```

Ввод [106]:

```
f1_predicted
```

Out[106]:

```
0.47150837988826816
```

Ввод [107]:

```
roc_auc_predicted
```

Out[107]:

```
0.7690277894404707
```

Что интересно - здесь практически без изменений

3.3.3. Вывод

Краткий вывод: два подхода - увеличение и уменьшение выборки - дали разные результаты.

Увеличение выборки привело к росту показателей f1 и roc_auc, лучше всего себя показал RandomForestClassifier с настройками n_estimators=60 и max_depth=17

Уменьшение выборки, наоборот, дало даунгрейд по сравнению с предыдущим методом. Это все еще лучше, чем совсем без обработки, но потерялись важные данные, без которых модель перестала предсказывать на достаточном уровне.

Стабильность - признак мастерства, и LogisticRegression показала одинаково плохие показатели в обоих случаях

3.4. Тестирование модели

Для тестов возьмем набор данных features_test и target_test из увеличенной выборки и обучим на RandomForestClassifier с лучшими настройками

Ввод [108]:

```
model = RandomForestClassifier(n_estimators=60,
                               max_depth=17,
                               random_state=12345)

model.fit(features_upsampled_train, target_upsampled_train)

predicted_test = model.predict(features_test)
```

f1-метрика:

Ввод [109]:

```
f1_score(target_test, predicted_test)
```

Out[109]:

```
0.6017925736235594
```

roc_auc-метрика:

Ввод [110]:

```
roc_auc_score(target_test, model.predict_proba(features_test)[:, 1])
```

Out[110]:

```
0.8484496129801644
```

Ввод [111]:

```
fpr, tpr, thresholds = roc_curve(target_test, model.predict_proba(features_test)[:,
```

Ввод [112]:

```
plt.figure(figsize=(12, 9))
plt.plot(list(range(len(fpr))), fpr, label='FPR')
plt.plot(list(range(len(fpr))), tpr, label='TPR')
plt.title('ROC_AUC')
plt.legend()
plt.grid()
```

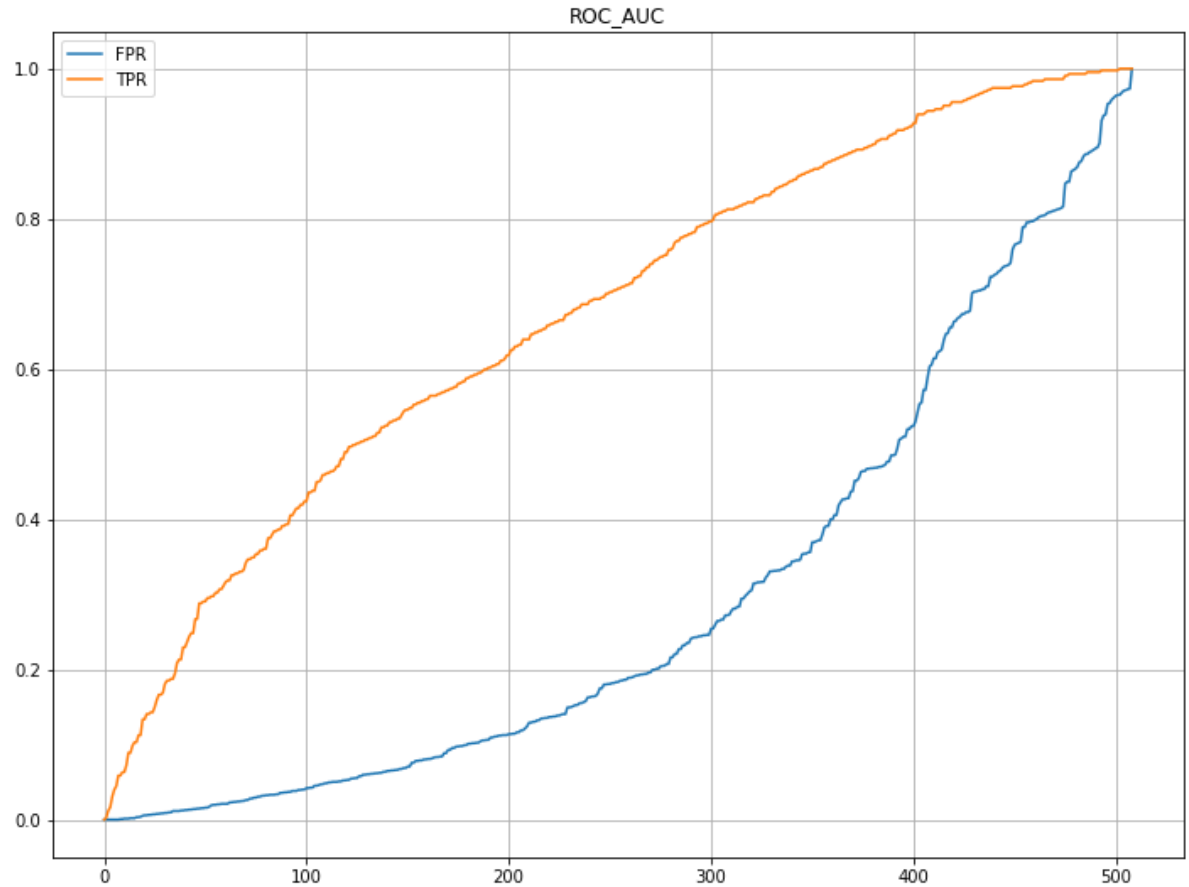

3.4.1. Вывод

Заметно, что модель слегка переобучилась. Показатели на тесте ниже, чем на валидации, но все еще в разумных пределах, порог мы прошли уверенно

3.5. Общий вывод

Мы получили данные о клиентах: их банковские продукты, количество лет пользования банком и прочее. Было убрано 3 лишних столбца: RowNumber, так как это лишь интерпретация индексов строк; а так же CustomerId и Surname, так как это данные, не имеющие значения для модели машинного обучения: они не несут никакого веса. Была проведена работа с таблицей: приведение к нижнему регистру, замена пропущенных значений в годах пользования банком на нули.

Было реализовано две ситуации: машинное обучение без балансировки классов, и с балансировкой.

Машинное обучение без балансировки показало одинаково плохие результаты: показатели были ниже пороговых, такие модели не стоит выпускать в продакшн – они отвечают заученными значениями, имеющими преимущество в наборе данных

Машинное обучение после балансировки показало значительно лучшие результаты: показатели метрик увеличились до 90+%. Хотя это и было следствием незначительного переобучения, лучшая модель – RandomForestClassifier – показала хороший результат: 0.77 f1-метрики и 0.86 roc-auc метрики, что на 36% превышает случайные ответы – не отлично, но и не ужасно. Такую модель можно использовать на реальных данных