1. Вводные данные

У нас в распоряжении имеются данные о продаже игр за несколько лет – названия, продажи в разных регионах, рейтинги и оценки критиков и пользователей. Наша задача – проверить данные, проанализировать их и сделать соответствующие выводы. Мы рассмотрим:

- Сколько игр выпускалось в разные годы

- Как менялись продажи по платформам

- Рассмотрим платформы с наибольшими суммарными продажами

- Выделим актуальный период для исследования

- Посмотрим, как влияют на продажи отзывы пользователей и критиков

- Построим распределение игр по жанрам

Ввод [1]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sb
from scipy import stats as st
```

Ввод [2]:

```
df = pd.read_csv('/datasets/games.csv')
```

Ввод [3]:

```
display(df.head())
print(df.shape)
```

	Name	Platform	Year_of_Release	Genre	NA_sales	EU_sales	JP_sales	Other_sales
0	Wii Sports	Wii	2006.0	Sports	41.36	28.96	3.77	8.45
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77
2	Mario Kart Wii	Wii	2008.0	Racing	15.68	12.76	3.79	3.29
3	Wii Sports Resort	Wii	2009.0	Sports	15.61	10.93	3.28	2.95
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00

```
(16715, 11)
```

Приведем все названия столбцов к нижнему регистру

Ввод [4]:

```
df.columns = df.columns.str.lower()
```

Ввод [5]:

```
df.head()
```

Out[5]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	c
0	Wii Sports	Wii	2006.0	Sports	41.36	28.96	3.77	8.45	
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	
2	Mario Kart Wii	Wii	2008.0	Racing	15.68	12.76	3.79	3.29	
3	Wii Sports Resort	Wii	2009.0	Sports	15.61	10.93	3.28	2.95	
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	

Исследуем данные

Ввод [6]:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16715 entries, 0 to 16714
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   name             16713 non-null  object
 1   platform         16715 non-null  object
 2   year_of_release  16446 non-null  float64
 3   genre            16713 non-null  object
 4   na_sales         16715 non-null  float64
 5   eu_sales         16715 non-null  float64
 6   jp_sales         16715 non-null  float64
 7   other_sales      16715 non-null  float64
 8   critic_score     8137 non-null   float64
 9   user_score       10014 non-null  object
 10  rating           9949 non-null   object
dtypes: float64(6), object(5)
memory usage: 1.4+ MB
```

Столбцы с названием, годом релиза, жанром, оценкой критиков, пользователей и возрастным рейтингом имеют ошибки. С них то мы и начнем

2. Обработка данных

2.1. Год релиза

Выведем игры, в которых неизвестен год релиза

Ввод [7]:

```
display(df[df.year_of_release.isna()].head())
print(df[df.year_of_release.isna()].shape)
```

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	c
183	Madden NFL 2004	PS2	NaN	Sports	4.26	0.26	0.01	0.71	
377	FIFA Soccer 2004	PS2	NaN	Sports	0.59	2.36	0.04	0.51	
456	LEGO Batman: The Videogame	Wii	NaN	Action	1.80	0.97	0.00	0.29	
475	wwe Smackdown vs. Raw 2006	PS2	NaN	Fighting	1.57	1.02	0.00	0.41	
609	Space Invaders	2600	NaN	Shooter	2.36	0.14	0.00	0.03	

```
(269, 11)
```

269 пропусков из 16715 строк данных: год достать очень непросто, так что мы выкинем эти данные

Ввод [8]:

```
df = df[df.year_of_release.notna()].reset_index(drop=True)
```

Ввод [9]:

```
display(df[df.year_of_release.isna()].head())
print(df[df.year_of_release.isna()].shape)
```

name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score

```
(0, 11)
```

Отлично, с годами разобрались

2.2. Оценки

Посмотрим на уникальность пользовательских оценок

Ввод [11]:

```
df.user_score.unique()
```

Out[11]:

```
array(['8', nan, '8.3', '8.5', '6.6', '8.4', '8.6', '7.7', '6.3', '7.
4',
       '8.2', '9', '7.9', '8.1', '8.7', '7.1', '3.4', '5.3', '4.8',
'3.2',
       '8.9', '6.4', '7.8', '7.5', '2.6', '7.2', '9.2', '7', '7.3',
'4.3',
       '7.6', '5.7', '5', '9.1', '6.5', 'tbd', '8.8', '6.9', '9.4',
'6.8',
       '6.1', '6.7', '5.4', '4', '4.9', '4.5', '9.3', '6.2', '4.2',
'6',
       '3.7', '4.1', '5.8', '5.6', '5.5', '4.4', '4.6', '5.9', '3.9',
       '3.1', '2.9', '5.2', '3.3', '4.7', '5.1', '3.5', '2.5', '1.9',
'3',
       '2.7', '2.2', '2', '9.5', '2.1', '3.6', '2.8', '1.8', '3.8',
'0',
       '1.6', '9.6', '2.4', '1.7', '1.1', '0.3', '1.5', '0.7', '1.2',
       '2.3', '0.5', '1.3', '0.2', '0.6', '1.4', '0.9', '1', '9.7'],
      dtype=object)
```

nan - это, конечно, хорошо, но tbd лучше

В интернетах пишут, что tbd - это от слова "to be definition", то есть еще не определено. Есть вероятность, что это совсем свежие, относительно данных, игры

Ввод [12]:

```
df[df.user_score == 'tbd'].year_of_release.unique()
```

Out[12]:

```
array([2010., 2005., 2011., 2009., 2004., 1999., 2001., 2008., 2007.,
       2003., 2000., 2006., 2002., 2015., 2014., 2012., 2013., 2016.,
       1997.])
```

Теория не подтвердилась, и, скорее всего, оценка за эти игры либо не была выставлена вообще, либо просто не подтянулась в данные

Ввод [13]:

```
df[df.user_score == 'tbd'].shape
```

Out[13]:

```
(2376, 11)
```

Ввод [14]:

```
df[df.user_score.isna()].shape
```

Out[14]:

```
(6607, 11)
```

Довольно много подобных строк, и оставлять их вообще без чистки будет вредно

Фактически, для нас это - nan, а значит надо привести к этому типу, чтобы заполнять все и сразу

Ввод [15]:

```
df.loc[df.user_score == 'tbd', 'user_score'] = np.nan
```

Ввод [16]:

```
df['user_score'] = df.user_score.astype(float)
```

Смотрим, сколько данных утеряно

Ввод [17]:

```
df[df.user_score.isna()].shape
```

Out[17]:

```
(8983, 11)
```

Подставить оценки, основанные на каких либо данных - не вариант, пары игра-платформа уникальны по годам, так что опереться не на что. Мы можем просто фильтровать данные при анализе, чтобы работать с известными

Ввод [18]:

```
df[(df.critic_score.notna()) |
   (df.user_score.notna()) |
   (df.rating.notna())].shape
```

Out[18]:

```
(9864, 11)
```

Небогато, но это лишь данные с оценками и рейтингами без пропусков всех их сразу

2.4. Название

Ввод [21]:

```
df[df.name.isna()]
```

Out[21]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_s
652	NaN	GEN	1993.0	NaN	1.78	0.53	0.00	0.08	
14022	NaN	GEN	1993.0	NaN	0.00	0.00	0.03	0.00	

В этих данных неизвестно почти все: год и рейтинг есть, но нет жанра и оценок. С таким мы далеко не уйдем

Решение изящное и элегантное - удаляем

Ввод [22]:

```
df = df[df.name.notna()].reset_index(drop=True)
```

Ввод [23]:

```
df[df.name.isna()]
```

Out[23]:

name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score

2.5. Жанр

Ввод [24]:

```
df[df.genre.isna()]
```

Out[24]:

name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score

Видимо, ушли вместе с предыдущими строками

3. Исследовательский анализ

3.1. Количество игр по годам

Ввод [28]:

```
ax = (df.pivot_table(index='year_of_release',
                     values='name',
                     aggfunc='count')
 .plot(kind='bar',
       figsize=(12, 9)))
ax.set_ylabel("games_sales_count")
```

Out[28]:

```
Text(0, 0.5, 'games_sales_count')
```

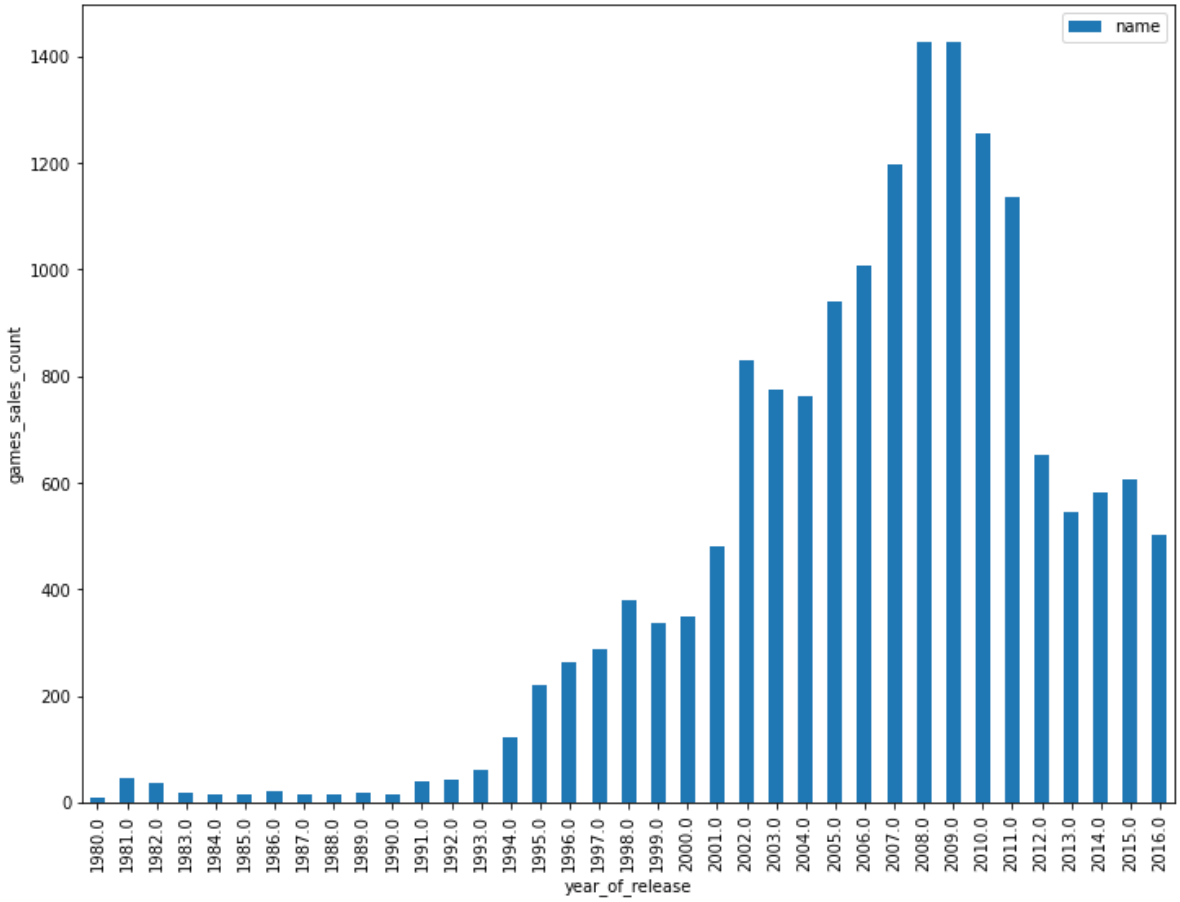

Допустим, нас в светлом будущем не очень интересуют данные о продажах в эпоху отсутствия Steam и иже с ними. Как минимум - хотя бы продажи более 200 копий

Ввод [29]:

```
df = df.query('year_of_release > 1994')
```

Ввод [30]:

```
ax = (df.pivot_table(index='year_of_release',
                     values='name',
                     aggfunc='count')
 .plot(kind='bar',
       figsize=(12, 9)))
ax.set_ylabel("games_sales_count")
```

Out[30]:

```
Text(0, 0.5, 'games_sales_count')
```

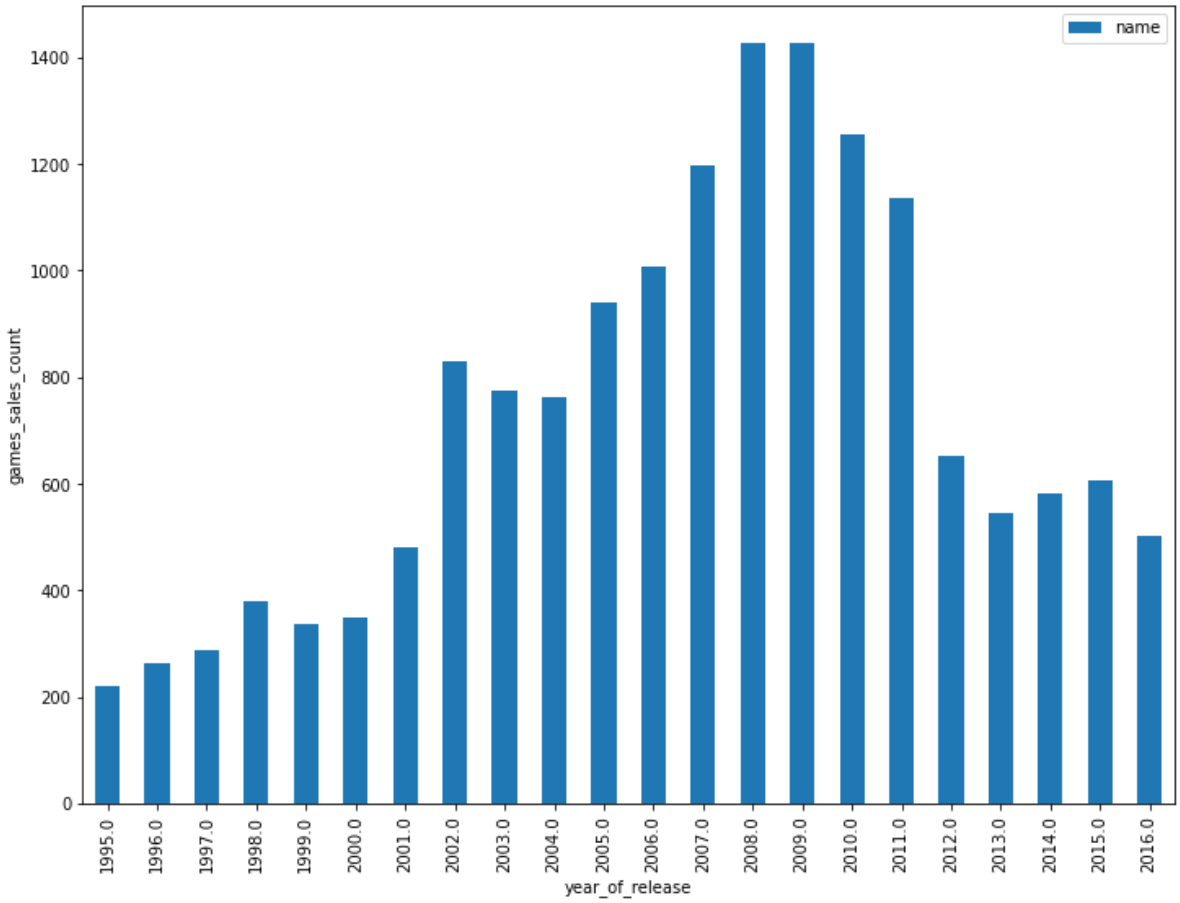

Теперь мы хотя бы будем работать с данными, имеющими вес

3.2. Популярные платформы

Ввод [31]:

```
(df.pivot_table(index=['year_of_release', 'platform'],
                values='summary_sales',
                aggfunc='sum')
 # сортируем по продажам, чтобы оставить наибольшие продажи внизу
 .sort_values(by='summary_sales')
 # убираем мульти-индекс
 .reset_index()
 # удаляем дубликаты, оставляя только последние
 .drop_duplicates('year_of_release', keep='last')
 # сортируем в привычный порядок лет
 .sort_values(by='year_of_release'))
```

Out[31]:

	year_of_release	platform	summary_sales
116	1995.0	PS	35.96
152	1996.0	PS	94.70
169	1997.0	PS	136.17
180	1998.0	PS	169.49
173	1999.0	PS	144.53
154	2000.0	PS	96.37
179	2001.0	PS2	166.43
184	2002.0	PS2	205.38
183	2003.0	PS2	184.31
186	2004.0	PS2	211.81
178	2005.0	PS2	160.66
170	2006.0	Wii	137.15
176	2007.0	Wii	152.77
182	2008.0	Wii	171.32
185	2009.0	Wii	206.97
181	2010.0	X360	170.03
177	2011.0	PS3	156.78
158	2012.0	PS3	107.36
159	2013.0	PS3	113.25
156	2014.0	PS4	100.00
161	2015.0	PS4	118.90
145	2016.0	PS4	69.25

Визуальные выводы: лидирует в основном PlayStation на любых этапах, есть целых 4 года лидерства Wii, иногда место занимает Xbox, но незначительно

Чуть интереснее - период смены поколений. Не уходя в анализ годов выпуска новых, можно заметить тенденцию на лидерство платформы в течении 4 лет

Соответственно, для нас таким будет как раз период 4 лет: в 2014, 2015 и 2016 году лидирует PS4, предполагаем, что в 2017 будет так же

3.3. Актуальный период

Срезаем не интересующие нас данные

Ввод [32]:

```
df = df.query('year_of_release > 2013')
```

Ввод [33]:

```
df.year_of_release.unique()
```

Out[33]:

```
array([2015., 2014., 2016.])
```

3.4. Продажи по платформам

Так как платформ много, а исследовать все не имеет смысла, возьмем топ продаж - по визуальным прикидкам это более 50

Ввод [34]:

```
df_top_platform = (df.pivot_table(index=['year_of_release', 'platform'],
               values='name',
               aggfunc='count')
 .sort_values(by='name')
 .reset_index()
 # на этом моменте срезаем количество выше 50
 .query('name >= 50')
 .sort_values(by='year_of_release'))
```

Ввод [35]:

```
df_top_platform
```

Out[35]:

	year_of_release	platform	name
15	2014.0	XOne	61
16	2014.0	X360	63
18	2014.0	PS4	75
19	2014.0	3DS	80
24	2014.0	PSV	100
25	2014.0	PS3	108
13	2015.0	PC	50
17	2015.0	PS3	73
20	2015.0	XOne	80
22	2015.0	3DS	86
26	2015.0	PSV	110
27	2015.0	PS4	137
14	2016.0	PC	54
21	2016.0	PSV	85
23	2016.0	XOne	87
28	2016.0	PS4	164

Данных много, визуально оценить сложно, нарисуем график

Ввод [36]:

```
fig, ax = plt.subplots()
for i in df_top_platform.platform.unique():
    df_top_platform.query('platform == @i').plot(x='year_of_release', y='name', labe
ax.set_ylabel("consoles_sales_count")
```

Out[36]:

```
Text(0, 0.5, 'consoles_sales_count')
```

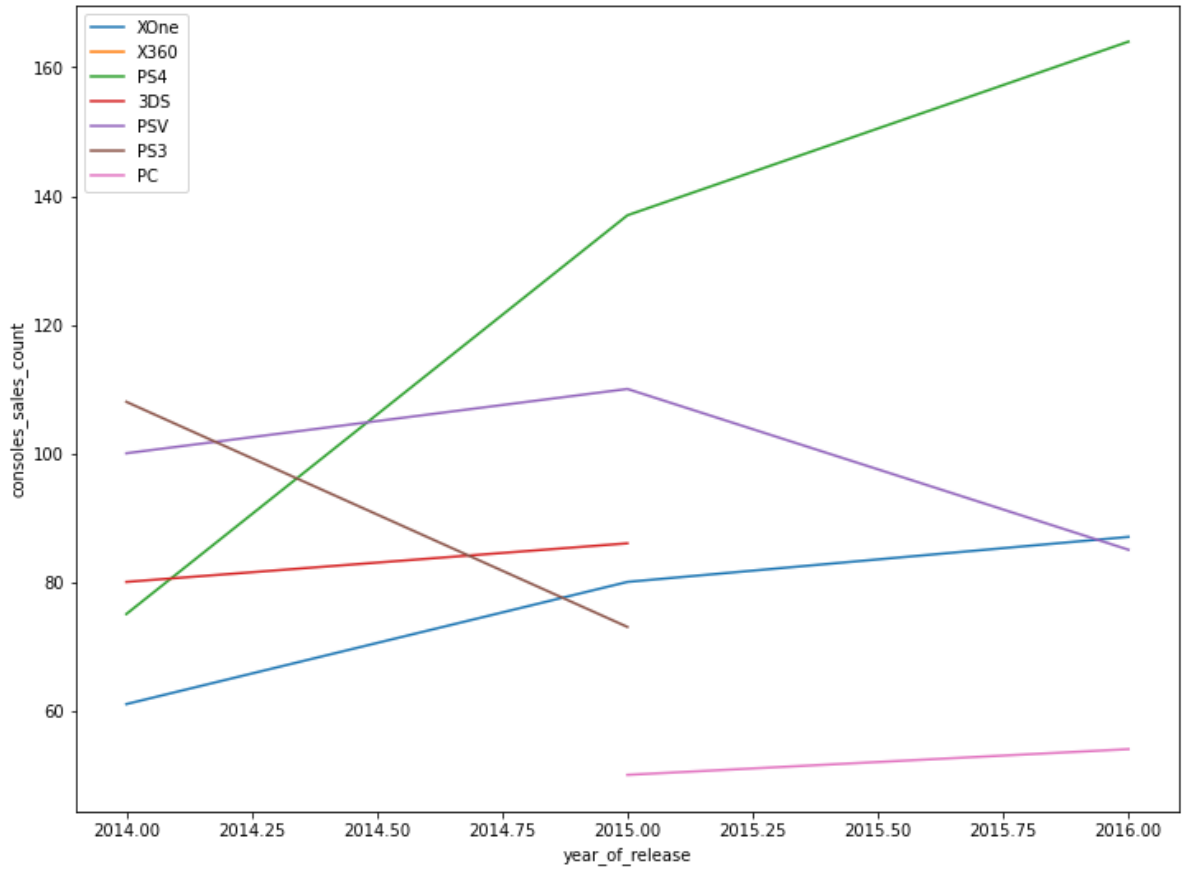

Здесь можно более четко увидеть уверенный рост PS4, не такой уверенный, но все еще рост Xbox One, уверенное падение PS3 и PS Vita, и робкий рост PC

Для себя делаем пометочку - обращать внимание в основном на Xbox One и PS4

3.5. Ящик с усами

Посмотрим, кто у нас остался из платформ

Ввод [37]:

```
df.platform.unique()
```

Out[37]:

```
array(['PS4', '3DS', 'XOne', 'WiiU', 'PS3', 'X360', 'PC', 'Wii', 'PS
V',
       'PSP'], dtype=object)
```

И построим по ним ящики с усами

Ввод [38]:

```
df.boxplot(column='summary_sales', by='platform', figsize=(12, 9))
```

Out[38]:

```
<AxesSubplot:title={'center':'summary_sales'}, xlabel='platform'>
```

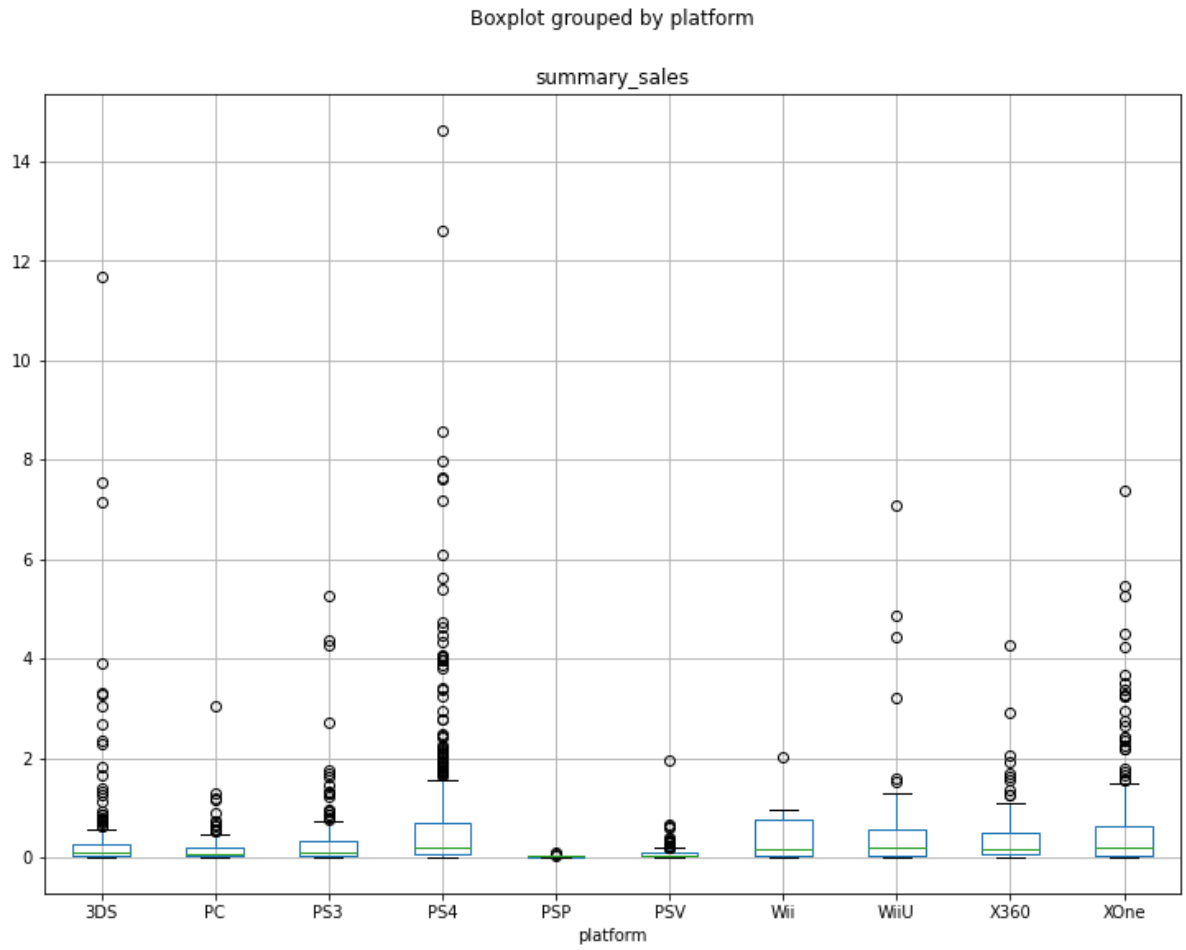

Мелкий формат хорошо показывает выбросы, но учитывая эксклюзивы для различных платформ, сложности с наличием другие и подобные эксцессы – на них можно пока не обращать внимание

Ввод [39]:

```
df.boxplot(column='summary_sales', by='platform', figsize=(12, 9))
plt.ylim(0, 2)
plt.show()
```

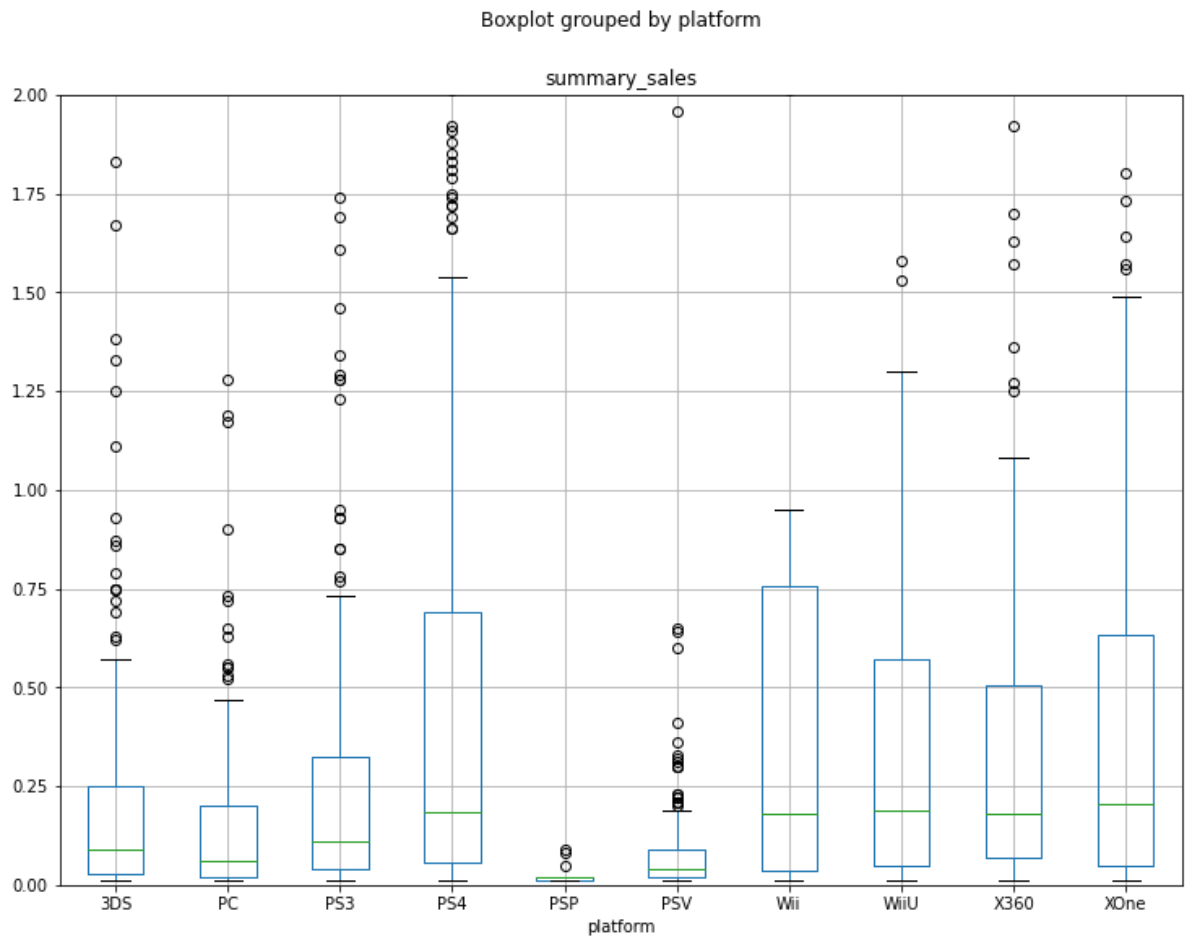

Здесь четко видны лидеры: Wii, WiiU, PS4, Xbox One

3.6. Влияние отзывов на продажи

Пойдем простым путем - построим скаттер плот по распределению отзывов критиков и продажам

Ввод [40]:

```
df.query('platform == "PS4" and critic_score.notna()').plot(x='critic_score',
                                        y='summary_sales',
                                        kind='scatter',
                                        figsize=(12, 9))
```

Out[40]:

```
<AxesSubplot:xlabel='critic_score', ylabel='summary_sales'>
```

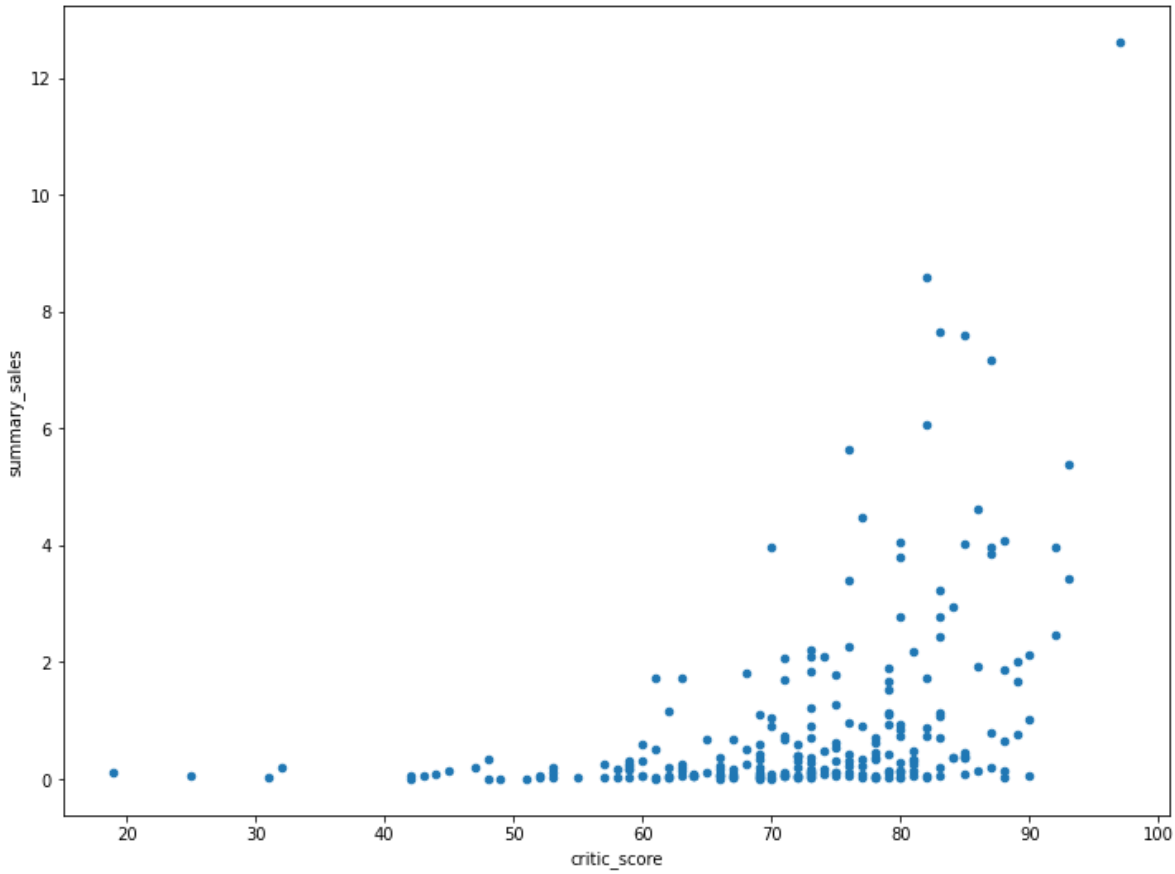

Здесь видна логичная закономерность - чем выше ставят оценку критики, тем сильнее растут продажи, но большинство продаж все еще сконцентрировано внизу графика

И посмотрим корреляцию

Ввод [41]:

```
df.query('platform == "PS4" and critic_score.notna()')[['summary_sales', 'critic_sco
```

Out[41]:

	summary_sales	critic_score
summary_sales	1.000000	0.402661
critic_score	0.402661	1.000000

40% – не так много, корреляция слабее, чем визуально на графике

Возьмем для сравнения другую платформу

Ввод [42]:

```
df.query('platform == "XOne" and critic_score.notna()').plot(x='critic_score',
                                                             y='summary_sales',
                                                             kind='scatter',
                                                             figsize=(12, 9))
```

Out[42]:

```
<AxesSubplot:xlabel='critic_score', ylabel='summary_sales'>
```

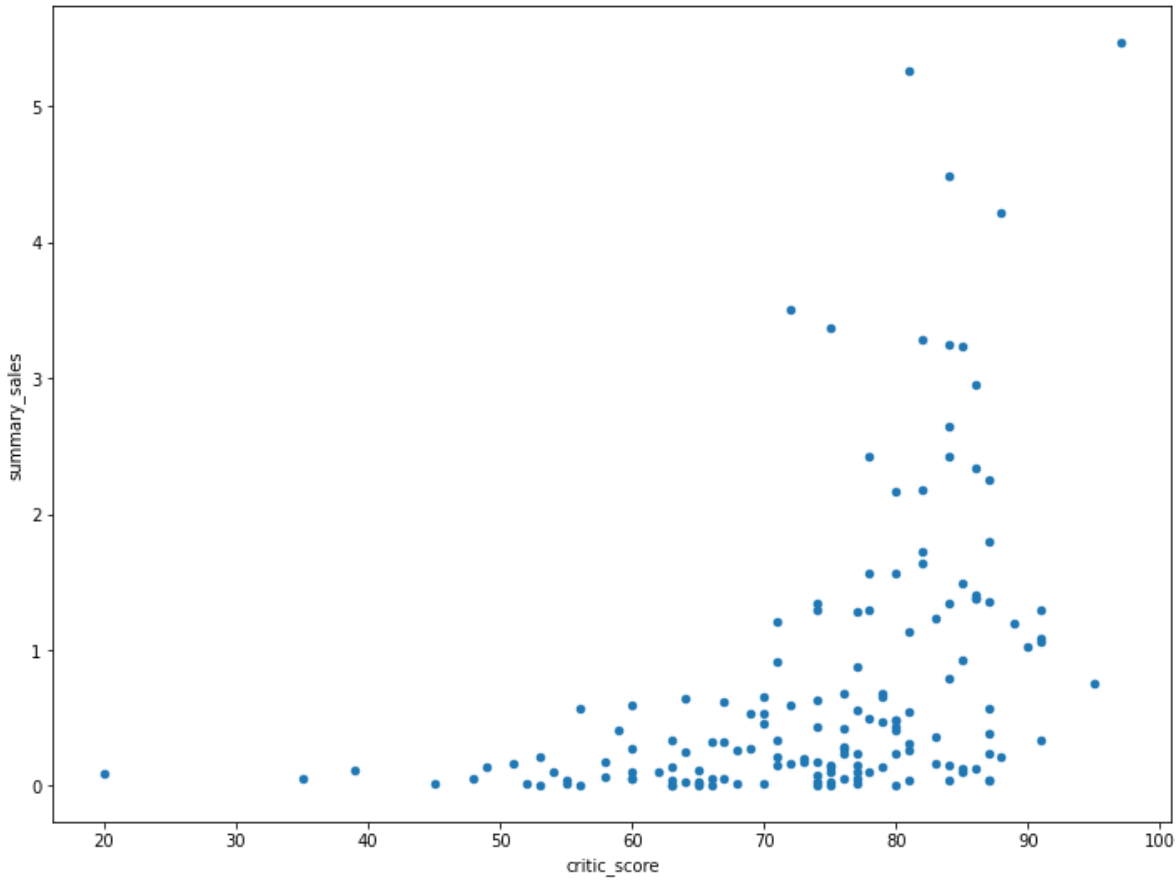

С графиком та же история

Ввод [43]:

```
df.query('platform == "XOne" and critic_score.notna()')[['summary_sales', 'critic_sc
```

Out[43]:

	summary_sales	critic_score
summary_sales	1.000000	0.428677
critic_score	0.428677	1.000000

Корреляция примерно на том же уровне, чуть выше - 42%

Для разнообразия посмотрим на график по всем платформам

Ввод [44]:

```
sb.set(rc={'figure.figsize':(15, 12)})
sb.scatterplot(x='critic_score',
               y='summary_sales',
               hue='platform',
               data=df.query('critic_score.notna()'))
```

Out[44]:

```
<AxesSubplot:xlabel='critic_score', ylabel='summary_sales'>
```

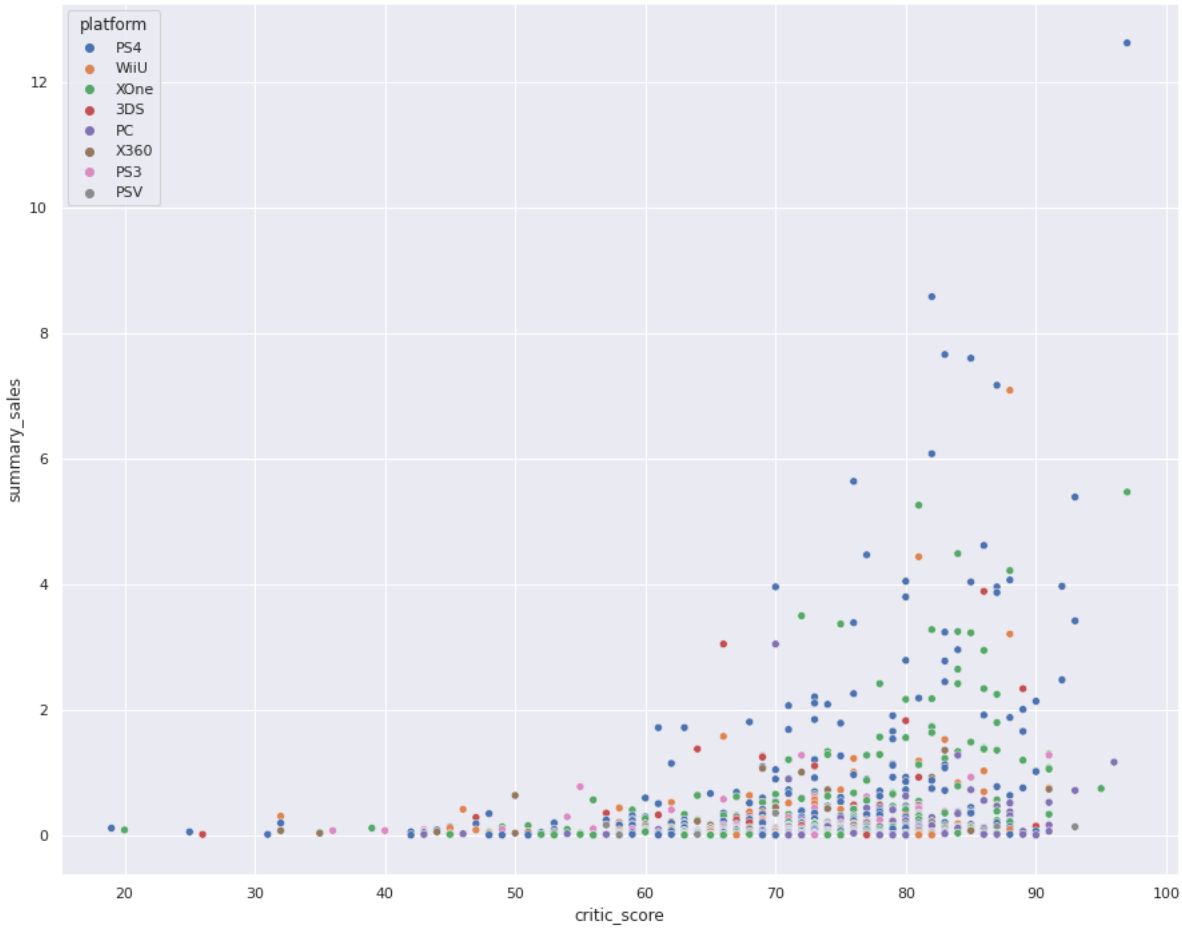

Отклонений от привычного уклада не наблюдается

Ввод [45]:

```
df.query('critic_score.notna()')[['summary_sales', 'critic_score']].corr()
```

Out[45]:

	summary_sales	critic_score
summary_sales	1.000000	0.328105
critic_score	0.328105	1.000000

Общая корреляция довольно слабая, это говорит нам о том, что хоть при низких оценках игру вообще не покупают в больших тиражах, но высокие оценки критиков очень слабо влияют на количество продаж

3.7. Распределение игр по жанрам

Посмотрим на самые продаваемые жанры

Ввод [46]:

```
ax = (df.pivot_table(index='genre', values='summary_sales', aggfunc='sum')
 .sort_values(by='summary_sales', ascending=False)
 .plot(kind='bar'))
ax.set_ylabel("summary_games_sales")
```

Out[46]:

```
Text(0, 0.5, 'summary_games_sales')
```

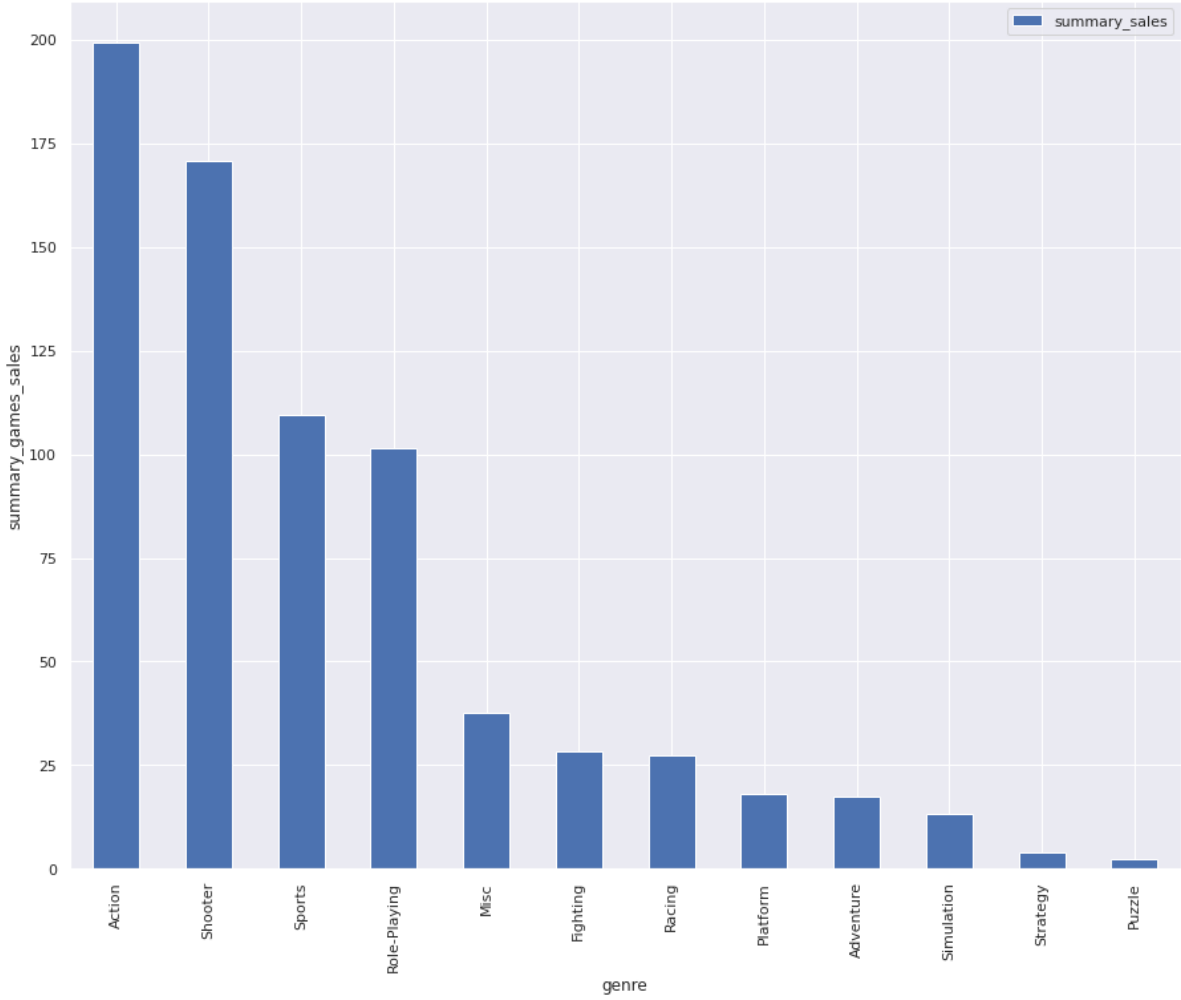

Лидируют Action и Shooter, уверенную планку держат Sports и Role-Playing

Посмотрим на средние показатели продаж

Ввод [47]:

```
ax = (df.pivot_table(index='genre', values='summary_sales', aggfunc='mean')
 .sort_values(by='summary_sales', ascending=False)
 .plot(kind='bar'))
ax.set_ylabel("summary_games_sales")
```

Out[47]:

```
Text(0, 0.5, 'summary_games_sales')
```

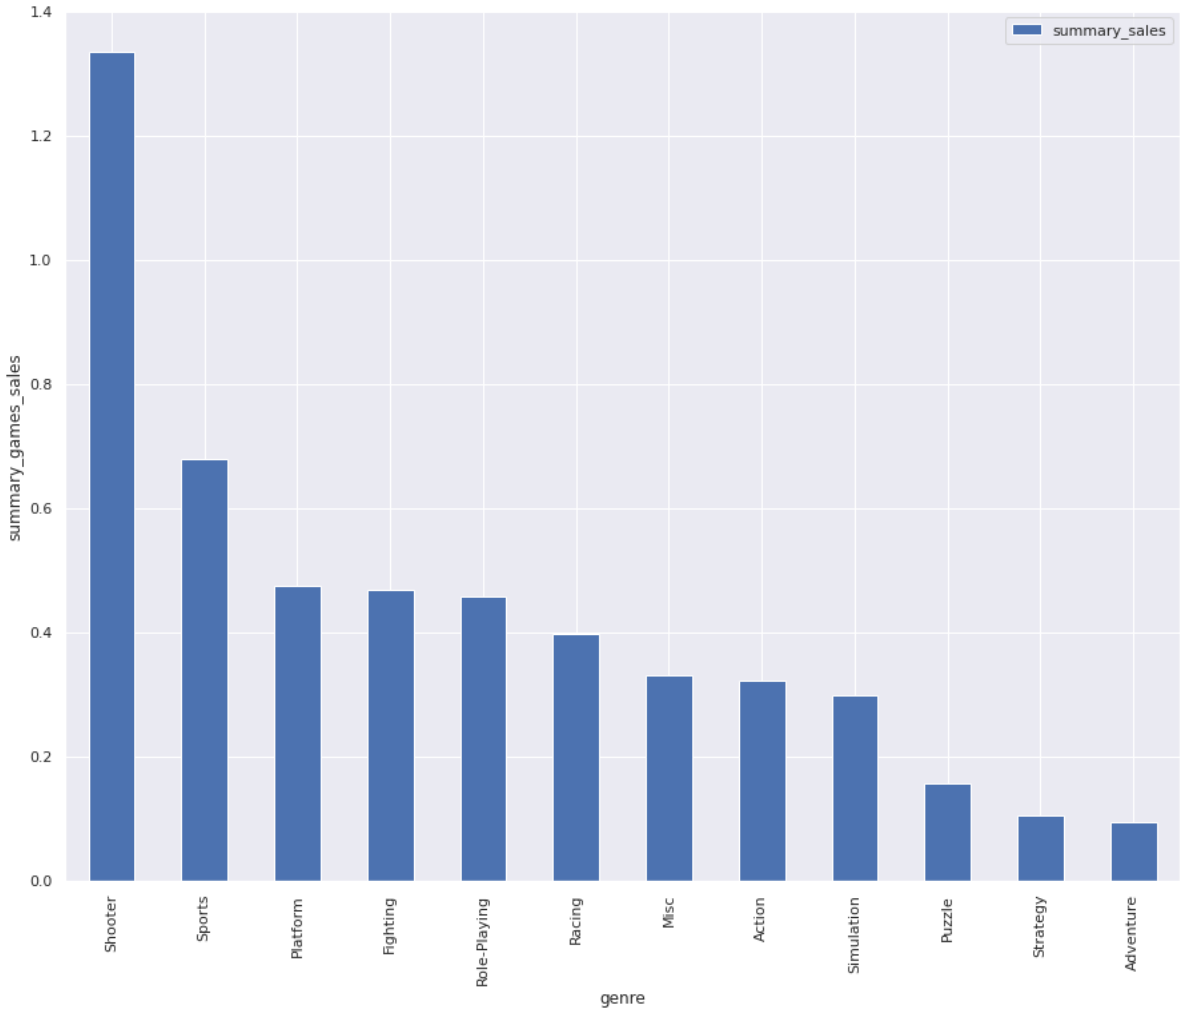

Здесь картина интереснее: Shooter в лидерах, на втором месте, но с большим отрывом Sports, остальные показатели кратно меньше

Можно сделать вывод, что суммарные данные и средние показатели сильно разнятся - могу сделать предположение, что вопрос цены, на Sports ценник выше, и среднее задирается, а на остальные жанры - ниже, хотя суммарно на них тратят больше, что говорит о большом количестве проданных копий

4. Портрет пользователя по регионам

Проведем процедуру анализа игроков из разных регионов по доступным нам данным

Ввод [48]:

```
temp = df.copy()
temp.rating = temp.rating.fillna('Na in country')
```

4.1. Самые популярные платформы

Ввод [49]:

```
na_platform_data = temp.pivot_table(index='platform',
                values='na_sales',
                aggfunc='sum').sort_values(by='na_sales',
               ascending=False).head()

eu_platform_data = (temp.pivot_table(index='platform',
                values='eu_sales',
                aggfunc='sum').sort_values(by='eu_sales',
               ascending=False)).head()

jp_platform_data = (temp.pivot_table(index='platform',
                values='jp_sales',
                aggfunc='sum').sort_values(by='jp_sales',
               ascending=False)).head()
```

Ввод [50]:

```
fig, ax = fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(15, 15))
ax1.pie(x=na_platform_data.na_sales, labels=na_platform_data.index)
ax1.set_title("NA")
ax2.pie(x=eu_platform_data.eu_sales, labels=eu_platform_data.index)
ax2.set_title("EU")
ax3.pie(x=jp_platform_data.jp_sales, labels=jp_platform_data.index)
ax3.set_title("JP")
plt.show()
```

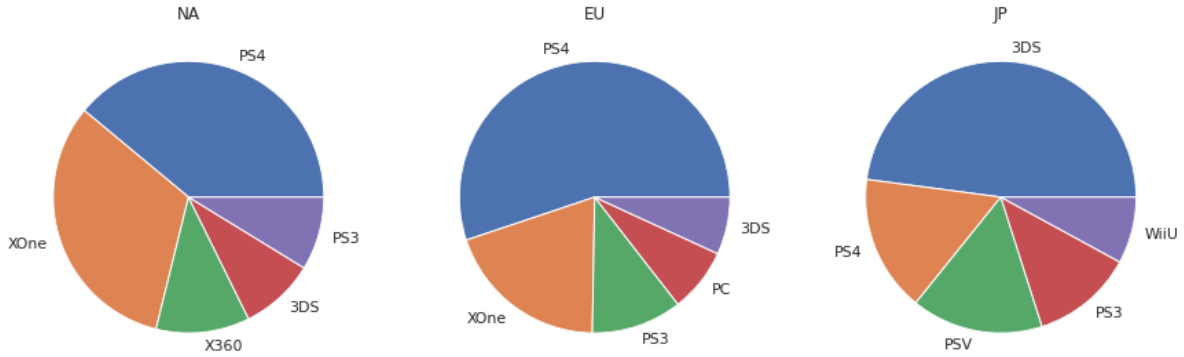

Игроки в na отдают предпочтение PS4 и Xbox One, остальные платформы сильно ниже по показателям

В eu есть более четкий лидер - PS4, все другие платформы значительно ниже по показателям

В далеком и таком непонятном jp лидирует 3DS; причем настолько, что остальные платформы нет смысла рассматривать как конкурентов

4.2. Самые популярные жанры

Ввод [51]:

```
na_genre_data = temp.pivot_table(index='genre',
                values='na_sales',
                aggfunc='sum').sort_values(by='na_sales',
               ascending=False).head()

eu_genre_data = (temp.pivot_table(index='genre',
                values='eu_sales',
                aggfunc='sum').sort_values(by='eu_sales',
               ascending=False)).head()

jp_genre_data = (temp.pivot_table(index='genre',
                values='jp_sales',
                aggfunc='sum').sort_values(by='jp_sales',
               ascending=False)).head()
```

Ввод [52]:

```
fig, ax = fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(15, 15))
ax1.pie(x=na_genre_data.na_sales, labels=na_genre_data.index)
ax1.set_title("NA")
ax2.pie(x=eu_genre_data.eu_sales, labels=eu_genre_data.index)
ax2.set_title("EU")
ax3.pie(x=jp_genre_data.jp_sales, labels=jp_genre_data.index)
ax3.set_title("JP")
plt.show()
```

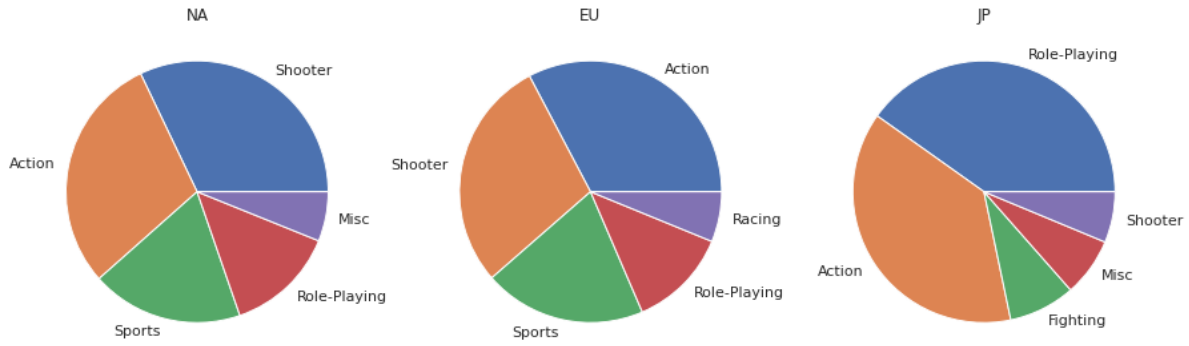

В na мы можем наблюдать плавный спад интереса - на первом месте Shooter, на втором с небольшим отставанием - Action. Остальные показатели идут с чуть большим разрывом

По жанрам в eu - такой же плавный спад интереса, тройка лидеров: Action, Shooter, Sports

У jp два четких, подавляющих лидера: Role_playing и Action

4.3. Влияние рейтинга ESRB

Ввод [53]:

```
na_rating_data = (temp.pivot_table(index='rating',
                values='na_sales',
                aggfunc='sum').sort_values(by='na_sales',
               ascending=False)).head()

eu_rating_data = (temp.pivot_table(index='rating',
                values='eu_sales',
                aggfunc='sum').sort_values(by='eu_sales',
               ascending=False)).head()

jp_rating_data = (temp.pivot_table(index='rating',
                values='jp_sales',
                aggfunc='sum').sort_values(by='jp_sales',
               ascending=False)).head()
```

Ввод [54]:

```
fig, ax = fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(15, 15))
ax1.pie(x=na_rating_data.na_sales, labels=na_rating_data.index)
ax1.set_title("NA")
ax2.pie(x=eu_rating_data.eu_sales, labels=eu_rating_data.index)
ax2.set_title("EU")
ax3.pie(x=jp_rating_data.jp_sales, labels=jp_rating_data.index)
ax3.set_title("JP")
plt.show()
```

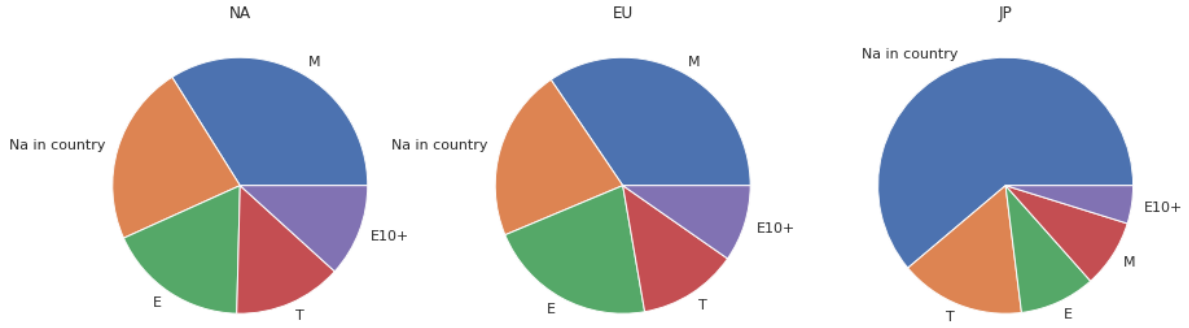

Тренд: в na игры с рейтингом M продаются лучше всего, вторым по счету идут игры без доступного рейтинга, остальные рейтинги не имеют такого уровня продаж, но не отличаются друг от друга критически

В eu история повторяется, но рейтинг E имеет чуть больший вес

jp отдают предпочтение играм, не имеющим рейтинг штатов, а остальные рейтинги суммарно дают меньше половины

4.4. Общий вывод

В na и eu игроки в целом похожи - любимые платформы PS4 и Xbox One, самый популярный жанр - Shooter. С jp история чуть более интересная - там лидирует платформа 3DS и жанр Role-Playing, однако, Action их всех объединяет

5. Проверка гипотез

5.1. Рейтинги платформ одинаковые

Нулевая гипотеза: рейтинг платформы Xbox One и Playstation 4 одинаковый

Это предположение, которое мы будем считать истиным, если оно подтвердится статистическими тестами. В ином случае, за истиную будет принята альтернативная гипотеза: рейтинги платформ Xbox One и Playstation 4 различаются

Рассчитаем средний рейтинг каждой платформы

Ввод [56]:

```
df.query('platform == "XOne" and user_score.notna()').loc[df.user_score.notnull(), '
```

Out[56]:

```
6.594545454545456
```

Ввод [57]:

```
df.query('platform == "PS4"  and user_score.notna()').loc[df.user_score.notnull(), '
```

Out[57]:

```
6.82809917355372
```

Визуально они очень похожи, но не лишним будет провести т-тест

Ввод [58]:

```
(st.ttest_ind(df.query('platform == "XOne" and user_score.notna()').loc[df.user_scor
                                                                        'user_score'
              df.query('platform == "PS4" and user_score.notna()').loc[df.user_score
                                                                       'user_score']
 .pvalue)
```

Out[58]:

```
0.09668975421672833
```

9% – в целом достаточно для положительного решения относительно нулевой гипотезы

Ответ: да, средний рейтинг платформ Xbox One и Playstation 4 одинаковый

5.2. Рейтинги жанров разные

Нулевая гипотеза: рейтинг жанра Action и жанра Sports разные

Данную гипотезу будем считать истиной в случае подтверждения тестом, иначе за истину возьмем альтернативную гипотезу: рейтинги жанров Action и Sports одинаковы

Ввод [59]:

```
df.query('genre == "Action" and user_score.notna()').loc[df.user_score.notnull(), 'u
```

Out[59]:

```
6.760606060606061
```

Ввод [60]:

```
df.query('genre == "Sports" and user_score.notna()').loc[df.user_score.notnull(), 'u
```

Out[60]:

```
5.2251968503937
```

Визуально они несколько отличаются, в масштабах 10-бальной шкалы довольно существенно, проведем тест

Ввод [61]:

```
(st.ttest_ind(df.query('genre == "Action" and user_score.notna()').loc[df.user_score
                                                                        'user_score']
              df.query('genre == "Sports" and user_score.notna()').loc[df.user_score
                                                                        'user_score']
 .pvalue)
```

Out[61]:

```
2.8711147985105864e-19
```

Крайне маленькое число с большим количеством нулей

Очевидно, нулевая гипотеза оказалась верной, так как выборки очень различаются

Ответ: да, средний рейтинг пользователей для жанров Action и Sports отличается

6. Общий вывод

Мы получили массив данных, с которым провели следующую работу:

Очистили данные от ошибок, заполнили пропуски логическими значениями, добавили столбец, суммирующий продажи во всех регионах

В процессе исследовательского анализа выяснили, что актуальный период поколения консолей, в основном, 4 года, в следствие чего использовали в будущем срез с 2014 года для анализа данных

Популярными платформами оказались ожидаемые PS4 и Xbox One, к ним присоеденились (по показателям продаж) Wii и WiiU, но это больше обусловлено не столько популярностью, сколько стоимостью игр (уже личный опыт)

Было выяснено, что отзывы критиков не так сильно влияют на продажи игр; скорее, низкие оценки стимулируют отсутствие продаж, нежели рост при высоких

Портреты пользователей из Америки и Европы оказались очень похожими: любимые платформы - PS4 и Xbox One, любимые жанры – Action и Sport; пользователи из Азии чуть более специфичны в своих вкусах – основной лидер в платформах 3DS, а в любимые жанры уверенно вмешивается Role-Playing

Так же статистическими тестами проверили и выяснили, что рейтинги основных платформ (PS4 и Xbox One) очень близки к одинаковым, а рейтинги среди различных жанров довольно отличны друг от друга